.UBAfiuba
FACULTAD DE INGENIERÍA

Arquitectura de inteligencia artificial para detección temprana de estrés hídrico en cultivos hortícolas bajo escenarios de escasez y variabilidad de datos

Esp. Lic. Gustavo Julián Rivas

Maestría en Inteligencia Artificial

Director: PhD. Ms. Camilo Enrique Argoty Pulido (FIUBA)

Jurados:

Dr. Lic. Esteban Mocskos (UBA)
Mg. Ing. Abelardo Pallich (UTN-FRBA)
Mg. Ing. Augusto Collado (UTN-FRBA)

Ciudad de Buenos Aires, diciembre de 2026

Resumen

En la presente memoria se describe el diseño e implementación de una arquitectura de inteligencia artificial orientada a la detección temprana de estrés hídrico en cultivos hortícolas bajo escenarios de escasez, ruido y variabilidad de datos. La arquitectura integra generación de datos sintéticos, detección de anomalías, modelado predictivo y retroalimentación humana. Estos componentes buscan mejorar la robustez del proceso predictivo y permitir la validación y recalibración progresiva de las alertas generadas.

El trabajo se centra en la inteligencia artificial como sistema de apoyo a la decisión, mientras que los sensores y demás fuentes de información se utilizan como insumos para la evaluación experimental.

Índice general

Resumen I

1. Introducción general 1
1.1. Contexto y motivación . . . 1
1.2. Estado del arte . . . 2
1.2.1. Estrés hídrico y variables de monitoreo . . . 2
1.2.2. Modelado predictivo de estrés hídrico . . . 2
1.2.3. Detección de anomalías y datos sintéticos . . . 3
1.2.4. Retroalimentación humana y recalibración de modelos . . . 3
1.2.5. Antecedentes regionales en Argentina . . . 4
1.3. Síntesis y vacancia identificada . . . 5
1.4. Objetivos y alcance del trabajo . . . 5

2. Introducción específica 6
2.1. Enfoque metodológico . . . 6
2.2. Formulación del problema y fuentes de datos . . . 7
2.3. Preparación y mecanismos de robustez . . . 8
2.4. Diseño experimental y estrategia de modelado . . . 9
2.5. Retroalimentación, reproducibilidad y validez . . . 11

3. Diseño e implementación 12
3.1. Arquitectura de la solución . . . 12
3.2. Implementación de los módulos de la aplicación . . . 13
3.2.1. Interfaz de consulta y servicio de aplicación . . . 13
3.2.2. Ingesta y preparación de observaciones . . . 14
3.2.3. Modelado predictivo y generación de alertas . . . 15
3.2.4. Retroalimentación humana y recalibración . . . 16
3.3. Registro de modelos y conservación de la información . . . 17
3.3.1. Identificación de versiones y antecedentes . . . 18
3.3.2. Correspondencia entre los datos y la actualización . . . 18
3.3.3. Registro de las condiciones de ejecución . . . 19
3.4. Despliegue de la aplicación con Docker . . . 19
3.5. Consulta del estado y tratamiento de incidencias . . . 19
3.6. Contratos de intercambio y recuperación del contexto . . . 20
3.7. Reproducción histórica y disponibilidad temporal . . . 21
3.8. Procedencia de las observaciones y valores derivados . . . 23
3.9. Persistencia y trazabilidad del feedback . . . 24
3.10. Integración del ensamble predictivo . . . 25
3.11. Empaquetado y carga de modelos . . . 27
3.12. Recorridos de demostración por sitio . . . 27
3.13. Condiciones para contrastar y revisar pronósticos . . . 29

4. Ensayos y resultados 30

4.1. Estrategia de evaluación 30
4.2. Comprobación del funcionamiento integrado 31
4.3. Evaluación de los mecanismos de robustez en Melchor Romero . . 31
4.3.1. Datos y condiciones experimentales 31
4.3.2. Resultados de las configuraciones 32
4.3.3. Disponibilidad de las observaciones 33
4.4. Evaluación temporal en Pergamino 34
4.4.1. Comparación de familias de modelos 34
4.4.2. Evaluación sobre períodos posteriores 34
4.4.3. Interpretación de las probabilidades 36
4.5. Evaluación del ensamble y del horizonte de anticipación 36
4.5.1. Preparación del estudio 36
4.5.2. Desempeño según el horizonte 37
4.5.3. Falsas alertas y omisiones 37
4.5.4. Anticipación de transiciones hacia baja humedad 38
4.5.5. Anticipación de episodios de baja humedad 39
4.5.6. Calibración de las salidas del ensamble 40
4.6. Evaluación de la retroalimentación y la recalibración 41
4.6.1. Efecto de correcciones simuladas 41
4.6.2. Prueba de interacción humana 42
4.7. Discusión de los resultados 42
4.8. Alcance de la evidencia respecto de la hipótesis 43
4.9. Limitaciones de la evaluación 43

5. Conclusiones **45**
5.1. Conclusiones generales 45
5.2. Trabajo futuro 46

Bibliografía **47**

Índice de figuras

2.1. Relación temporal entre las entradas de la predicción emitida en t y la observación objetivo en $t + 3$. 8

3.1. Arquitectura de la aplicación base y despliegue con Docker. 13
3.2. Recorrido de reproducción histórica y registro de feedback. 25

4.1. Coeficiente de correlación de Matthews obtenido por las configuraciones evaluadas en Melchor Romero. 33
4.2. Evolución del coeficiente de correlación de Matthews según el horizonte de predicción para el ensamble por promedio, la regresión logística y la persistencia. 37
4.3. Proporción de transiciones hacia la condición de baja humedad identificadas por cada método según el horizonte de predicción. . . 39
4.4. Relación entre la salida media del ensamble y la proporción observada de casos positivos para el horizonte de tres días. 40

Índice de tablas

3.1. Modelos de la aplicación base y de los componentes experimentales. 16
3.2. Controles previos a la ejecución. 20
3.3. Referencias temporales de la reproducción histórica. 22
3.4. Estados de procedencia de las observaciones en el historial. 23
3.5. Ejemplos ilustrativos de decisión conjunta y votos positivos. 26
3.6. Propósito y datos de los recorridos de demostración. 28

4.1. Resultados de las configuraciones evaluadas en Melchor Romero sobre 67 casos comunes. 32
4.2. Comparación de familias de modelos durante el desarrollo con datos de Pergamino. 34
4.3. Resultados de la regresión logística y de la persistencia a tres días en Pergamino. 35
4.4. MCC de los modelos y sus combinaciones en Pergamino durante 2023. 37
4.5. Falsas alertas y omisiones según el horizonte de predicción. 38
4.6. Identificación de transiciones hacia la condición de baja humedad. 39
4.7. Episodios de baja humedad identificados según el horizonte de predicción. 40
4.8. MCC por semilla en la evaluación de correcciones simuladas. . . . 42

Capítulo 1

Introducción general

En este capítulo se presenta el contexto del trabajo, los principales antecedentes sobre detección temprana de estrés hídrico mediante inteligencia artificial y la vacancia que fundamentó el diseño de la arquitectura desarrollada.

1.1. Contexto y motivación

El estrés hídrico en cultivos hortícolas se produce cuando la disponibilidad de agua resulta insuficiente para satisfacer adecuadamente las necesidades fisiológicas de la planta. Dependiendo de su intensidad y duración, esta condición puede afectar el crecimiento vegetativo, el rendimiento y la calidad comercial de la producción. De manera complementaria, un aporte de agua superior al requerido también puede generar efectos adversos relacionados con el uso ineficiente del recurso hídrico, un mayor consumo energético y determinadas condiciones sanitarias desfavorables.

La detección temprana de estas situaciones resulta relevante porque permite disponer de información sobre la evolución de las condiciones hídricas antes de que sus efectos produzcan daños significativos sobre el cultivo. En numerosos entornos productivos, las decisiones de riego continúan apoyándose en la observación directa, la experiencia acumulada del productor y reglas operativas predefinidas. Estos mecanismos forman parte del conocimiento agronómico necesario para el manejo de los cultivos, pero pueden presentar limitaciones cuando las condiciones ambientales varían rápidamente o cuando deben interpretarse de manera simultánea diferentes fuentes de información.

El desarrollo de la agricultura digital y de la agricultura de precisión amplió las posibilidades de observación mediante sensores de suelo, estaciones meteorológicas, imágenes remotas y otras fuentes de datos. Sin embargo, disponer de mediciones no implica necesariamente contar con información adecuada para entrenar y evaluar modelos predictivos. Las series obtenidas en contextos agrícolas pueden contener valores faltantes, ruido, lecturas anómalas, diferencias en la frecuencia de muestreo y variaciones asociadas a cambios ambientales o productivos.

Estas dificultades adquieren especial relevancia en explotaciones hortícolas de pequeña y mediana escala, donde pueden no existir registros históricos suficientemente extensos ni conjuntos de datos previamente etiquetados. A esta limitación se suma la variabilidad entre campañas, cultivos, condiciones ambientales y prácticas de manejo, lo que dificulta la transferencia directa de modelos entrenados en otros contextos.

El trabajo propuesto en esta memoria se orienta a abordar, mediante técnicas de inteligencia artificial, las problemáticas identificadas para la detección temprana del estrés hídrico en cultivos hortícolas. En los capítulos siguientes se presentan el enfoque adoptado, su desarrollo y los criterios utilizados para su evaluación.

Sobre esta base se formuló la hipótesis de que la combinación de generación de datos sintéticos, detección de anomalías, modelado predictivo y retroalimentación humana puede mejorar la detección temprana de condiciones de estrés hídrico respecto de configuraciones de referencia, particularmente bajo escenarios caracterizados por disponibilidad limitada, ruido y variabilidad de datos. La estrategia experimental fue definida para analizar tanto el desempeño global de la arquitectura como el aporte individual y conjunto de sus componentes.

1.2. Estado del arte

La revisión de antecedentes se orientó a identificar los enfoques utilizados para caracterizar y predecir condiciones de estrés hídrico y los mecanismos que pueden contribuir a mejorar la confiabilidad del proceso predictivo cuando los datos disponibles resultan limitados o presentan problemas de calidad. El análisis se organizó de acuerdo con los principales componentes considerados en la arquitectura y se complementó con antecedentes relacionados con las variables agronómicas y ambientales utilizadas para representar el fenómeno.

1.2.1. Estrés hídrico y variables de monitoreo

En la literatura relevada, el estrés hídrico se define como una condición fisiológica derivada de una disponibilidad insuficiente de agua para el cultivo, con efectos observables tanto mediante variables fisiológicas directas, como el potencial hídrico foliar y la conductancia estomática, como mediante variables indirectas o *proxy*, entre ellas la humedad del suelo, la temperatura de canopia y los índices de vegetación [1].

Las variables climáticas como temperatura, humedad relativa, precipitación, radiación solar y velocidad del viento permiten caracterizar las condiciones atmosféricas asociadas con la demanda hídrica. Estas variables constituyen además insumos para el cálculo de la evapotranspiración de referencia, magnitud ampliamente utilizada en el manejo hídrico agrícola y habitualmente estimada mediante el método de Penman–Monteith [2].

Entre las variables agronómicas, la humedad del suelo proporciona información sobre la disponibilidad de agua en la zona radicular. Por su parte, la temperatura de canopia obtenida mediante sensado remoto y los índices derivados de imágenes multiespectrales permiten observar respuestas indirectas asociadas con el estado hídrico del cultivo [3].

1.2.2. Modelado predictivo de estrés hídrico

El modelado predictivo del estrés hídrico comprende diferentes técnicas de aprendizaje automático y aprendizaje profundo. La literatura relevada incluye métodos como bosques aleatorios, máquinas de vectores de soporte, redes neuronales artificiales y arquitecturas convolucionales aplicadas sobre datos de sensores de

suelo, imágenes obtenidas mediante vehículos aéreos no tripulados, información satelital y mediciones fisiológicas [1].

Un antecedente de esta línea corresponde al mapeo de humedad de suelo de alta resolución mediante bosques aleatorios cuantílicos, combinando mediciones *in situ* con variables satelitales, topográficas y edáficas [4]. Este enfoque evidencia la capacidad de los modelos de aprendizaje automático para integrar diferentes fuentes de información, aunque su objetivo se encuentra orientado al mapeo regional y no específicamente a la generación de alertas tempranas a escala de una unidad hortícola.

Los antecedentes analizados muestran que la selección de una técnica depende, entre otros factores, del número de observaciones disponibles, de la estructura temporal de los datos, de la calidad de las etiquetas y de la variable que se desea predecir. Por este motivo, no resulta adecuado establecer una única familia de algoritmos como solución general para todos los escenarios.

1.2.3. Detección de anomalías y datos sintéticos

La presencia de errores de medición, valores atípicos o fallas de sensores constituye una fuente de incertidumbre capaz de afectar tanto el entrenamiento como la inferencia de los modelos predictivos. Cuando estos valores no son identificados adecuadamente, pueden introducir patrones que no representan el comportamiento real de las variables observadas.

La utilización de datos sintéticos introduce, sin embargo, la necesidad de verificar que la información generada preserve características relevantes del fenómeno estudiado. Por este motivo, su incorporación no se considera beneficiosa por definición. Su utilidad debe determinarse experimentalmente tanto mediante el análisis de su similitud con los datos reales como a partir de su efecto sobre el desempeño del modelo predictivo.

1.2.4. Retroalimentación humana y recalibración de modelos

La retroalimentación humana en sistemas de inteligencia artificial, denominada habitualmente *human-in-the-loop*, incorpora la intervención de una persona en diferentes etapas del ciclo de aprendizaje. Esta participación puede incluir el etiquetado de observaciones, la validación de predicciones, la corrección de errores y la decisión de utilizar nueva información en procesos posteriores de entrenamiento [5].

El marco HILAD propone un ciclo bidireccional para la detección de anomalías en series temporales, en el que las observaciones realizadas por el operador son reincorporadas iterativamente al proceso de aprendizaje [6]. Aunque este enfoque no fue diseñado específicamente para sensores agrícolas ni para estrés hídrico, constituye un antecedente metodológico relevante para analizar de qué manera una validación humana puede transformarse en información utilizable posteriormente por un modelo.

Un aspecto adicional de los sistemas con retroalimentación humana consiste en determinar cuándo resulta conveniente solicitar una validación. La confianza o incertidumbre asociada a una predicción puede utilizarse como criterio para priorizar aquellas alertas que requieren intervención humana, lo que evita que todas las salidas del modelo demanden el mismo nivel de supervisión. Este enfoque

vincula la retroalimentación con estrategias de aprendizaje interactivo y permite concentrar la intervención humana en los casos de mayor incertidumbre.

1.2.5. Antecedentes regionales en Argentina

Un estudio realizado sobre la región pampeana estimó el estrés hídrico en cultivos extensivos mediante un índice derivado de imágenes de temperatura de superficie y analizó su relación con el rendimiento de soja, maíz y trigo en diferentes ecorregiones [7]. Si bien este trabajo demuestra la utilidad de información térmica y de índices de vegetación para caracterizar condiciones hídricas, su escala espacial y los cultivos considerados difieren del escenario hortícola abordado en este trabajo.

Con el propósito de sintetizar las principales líneas identificadas en la literatura y explicitar su relación con el problema abordado, se describen algunos de los antecedentes más representativos del corpus relevado. La selección comprende trabajos vinculados con modelado predictivo, detección de anomalías, generación de datos sintéticos, retroalimentación humana y antecedentes regionales.

Los antecedentes comparados abordan dimensiones complementarias del problema. Cho et al. [1] sintetizan las variables y técnicas empleadas para evaluar el estrés hídrico, aunque no proponen una arquitectura que integre los mecanismos considerados en este trabajo. DeepQC [8] automatiza el control de calidad de series temporales de humedad del suelo, pero se concentra en la calidad de los datos y no en la generación de alertas tempranas. Los métodos autosupervisados [9] permiten identificar sensores o mediciones anómalas sin disponer de etiquetas previas, aunque no integran el modelado predictivo. Las revisiones sobre autoencoders variacionales y redes generativas adversarias [10] reúnen técnicas para generar datos sintéticos agrícolas, pero no se enfocan específicamente en series temporales cortas de estrés hídrico en horticultura.

Los enfoques con intervención humana también proporcionan antecedentes parciales. HILAD [6] propone un ciclo bidireccional en el que la validación humana realimenta el aprendizaje, aunque su dominio no corresponde a la agricultura. Basnayake et al. [11] aportan fundamentos para incorporar supervisión humana en agricultura de precisión, pero no definen un mecanismo específico de recalibración para la predicción del estrés hídrico. El estudio regional sobre cultivares de tomate [12] aporta evidencia fisiológica sobre la respuesta de un cultivo hortícola frente al estrés, aunque no incorpora monitoreo continuo ni modelado predictivo. El sensor desarrollado por el INTA [13] evidencia la disponibilidad local de instrumentación compatible con cultivos de pequeña y mediana escala, pero corresponde a adquisición de datos y no a inteligencia artificial.

La comparación muestra que los antecedentes relevados proporcionan fundamentos específicos para los distintos componentes considerados en el trabajo, pero los abordan principalmente de forma independiente o mediante integraciones parciales. En el corpus analizado no se identificó una arquitectura aplicada a la detección temprana de estrés hídrico en horticultura que integre generación de datos sintéticos, detección de anomalías, modelado predictivo y retroalimentación humana y que permita, además, evaluar experimentalmente su contribución individual y conjunta.

1.3. Síntesis y vacancia identificada

El análisis de los antecedentes permitió identificar cuatro líneas de trabajo relacionadas con el problema estudiado. La primera corresponde al modelado predictivo de variables asociadas al estado hídrico mediante técnicas de aprendizaje automático. La segunda comprende métodos destinados a detectar anomalías o degradaciones en las mediciones. La tercera aborda la generación de datos sintéticos como mecanismo para complementar conjuntos de entrenamiento limitados. La cuarta incorpora retroalimentación humana para validar resultados y aportar nueva información al proceso de aprendizaje.

Cada una de estas líneas presenta antecedentes propios y diferentes niveles de desarrollo. Sin embargo, en el corpus relevado se observó que habitualmente fueron estudiadas de manera independiente o mediante combinaciones parciales. No se identificó un enfoque aplicado al estrés hídrico en horticultura de pequeña y mediana escala que integrara los cuatro componentes dentro de una misma arquitectura y permitiera evaluar experimentalmente su contribución individual y conjunta.

La vacancia identificada motivó el desarrollo de una arquitectura que integró generación de datos sintéticos, detección de anomalías, predicción y retroalimentación humana para analizar su contribución ante limitaciones de disponibilidad y calidad de los datos.

1.4. Objetivos y alcance del trabajo

El objetivo general fue diseñar, implementar y evaluar una arquitectura de inteligencia artificial para anticipar condiciones de baja humedad del suelo asociadas con el estrés hídrico, como apoyo a las decisiones en horticultura de pequeña y mediana escala.

Los objetivos específicos fueron:

- Preparar series temporales con criterios de calidad y orden temporal.
- Estimar la probabilidad de que la humedad del suelo se situara tres días después por debajo del percentil veinte calculado sobre los datos de entrenamiento.
- Comparar configuraciones con y sin datos sintéticos y detección de anomalías ante escasez y ruido. Para la comparación se estableció el coeficiente de correlación de Matthews como métrica principal, acompañado de métricas complementarias y referencias de predicción.
- Integrar la consulta de alertas, su revisión humana y el registro de correcciones para posteriores recalibraciones, con trazabilidad de datos y modelos.

El alcance comprendió un prototipo funcional y su evaluación con series públicas de humedad del suelo y variables meteorológicas. La condición predicha se definió mediante un umbral relativo y no constituyó un diagnóstico fisiológico del cultivo. Quedaron fuera del alcance la adquisición de mediciones mediante sensores físicos, el control automático del riego y la validación agronómica en campo. La incorporación de retroalimentación humana no implicó por sí sola una mejora predictiva demostrada.

Capítulo 2

Introducción específica

Este capítulo presenta la metodología aplicada durante el desarrollo y la evaluación de la arquitectura. El enfoque comprendió la causalidad temporal, los mecanismos de robustez, la comparación de configuraciones, la retroalimentación humana y la reproducibilidad experimental.

2.1. Enfoque metodológico

El trabajo se desarrolló como una investigación aplicada de naturaleza cuantitativa, orientada a construir y evaluar un artefacto de inteligencia artificial para apoyar la detección temprana de condiciones compatibles con estrés hídrico. La contribución no se limitó al entrenamiento de un predictor, sino que comprendió el proceso que vinculó la adquisición y el control de calidad de los datos con la construcción de variables temporales, la emisión de alertas, la revisión humana y la recalibración trazable de los modelos.

El objeto de estudio se delimitó como una arquitectura computacional que transformó observaciones agroclimáticas en evidencia predictiva trazable. El análisis se concentró en los mecanismos de inteligencia artificial comprendidos entre los datos y la alerta, no en la construcción de una red de sensores. La preparación causal, la detección de anomalías, la generación controlada de datos sintéticos, el modelado y la retroalimentación humana constituyeron los componentes evaluados.

La unidad de evidencia se definió como una ejecución reconstruible, no como una métrica aislada. Cada ejecución comprendió la identidad del conjunto de datos, las reglas de preparación, las fronteras temporales, la configuración del modelo, las semillas, las predicciones y las métricas. El repositorio materializó esta definición mediante contratos, artefactos estructurados y huellas criptográficas. Una comparación se consideró interpretable solo cuando las configuraciones compartieron el objetivo, el horizonte y el período de evaluación.

Una línea base científica preservó los resultados utilizados para contrastar la hipótesis, mientras que una línea base técnica permitió evolucionar la infraestructura y la trazabilidad sin alterar la evidencia. Esta separación permitió distinguir la integración funcional de la mejora predictiva. Los resultados se circunscribieron a las fuentes, las localizaciones y los períodos evaluados. A su vez, el linaje entre versiones acreditó la procedencia, pero no demostró una mejora sin una evaluación posterior e independiente.

Como marco de trabajo se adaptó CRISP-DM (*Cross-Industry Standard Process for Data Mining*) [14]. La adaptación comprendió el entendimiento del problema y de los datos, la preparación, el modelado, la evaluación y el despliegue. Las fases se aplicaron de manera iterativa. El despliegue se materializó mediante un prototipo local demostrable, sin constituir un sistema productivo de riego.

Se adoptó una estrategia incremental y modular. Los mecanismos de preparación, detección de anomalías, generación sintética, predicción y retroalimentación se definieron mediante entradas y salidas explícitas. Esta separación permitió activar o desactivar componentes y atribuir las diferencias observadas a mecanismos concretos. Los sensores y las fuentes agroclimáticas se consideraron insumos. La contribución central se concentró en los mecanismos de inteligencia artificial y en su evaluación bajo escenarios de escasez, ruido y variabilidad de los datos.

La evaluación se realizó con series de datos correspondientes a la localidad de Melchor Romero. La humedad del suelo se obtuvo del producto combinado ESA CCI Soil Moisture [15, 16, 17] y las variables meteorológicas, de NASA POWER [18]. Estas fuentes proporcionaron estimaciones satelitales y productos meteorológicos, no mediciones de sensores instalados en el lugar. La evidencia obtenida se preservó de manera independiente de las modificaciones técnicas posteriores.

La distinción entre funcionamiento y desempeño orientó la interpretación de la evidencia. El funcionamiento permitió comprobar que las observaciones atravesaran el proceso y produjeran una salida susceptible de revisión. El desempeño, en cambio, se examinó mediante la comparación de las predicciones con los resultados observados. Que el prototipo completara sus operaciones no implicó que sus alertas fueran más precisas ni que la incorporación de un componente mejorara la predicción.

2.2. Formulación del problema y fuentes de datos

La unidad de análisis se definió como una observación diaria asociada con una localización o un sensor. Para cada fecha de emisión t, se utilizó únicamente la información disponible hasta ese momento. El objetivo consistió en estimar la probabilidad de que la humedad observada tres días después se encontrara por debajo de un umbral relativo calculado con datos de entrenamiento.

La variable objetivo y_t tomó el valor uno cuando la humedad s_{t+3} fue inferior al percentil 20 del entrenamiento autorizado, y cero en caso contrario. Este umbral caracterizó una condición hídrica relativa dentro del dominio analizado y se diferenció del umbral de decisión, fijado en $0{,}5$, que se utilizó para transformar una probabilidad en una clase durante la comparación principal. La salida se interpretó como una alerta probabilística y no como un diagnóstico fisiológico ni una prescripción automática de riego.

La formulación separó la información utilizada para predecir de la observación empleada para comprobar el resultado. Una variable de entrada describió condiciones conocidas en la fecha de emisión, mientras que la etiqueta correspondió a una fecha posterior. Esta diferencia temporal fue necesaria para interpretar la tarea como una predicción y evitar que el modelo recibiera información del resultado que debía anticipar.

La figura 2.1 sintetiza la relación entre la información disponible en la fecha de emisión, el horizonte de tres días y la observación posterior utilizada para contrastar la predicción.

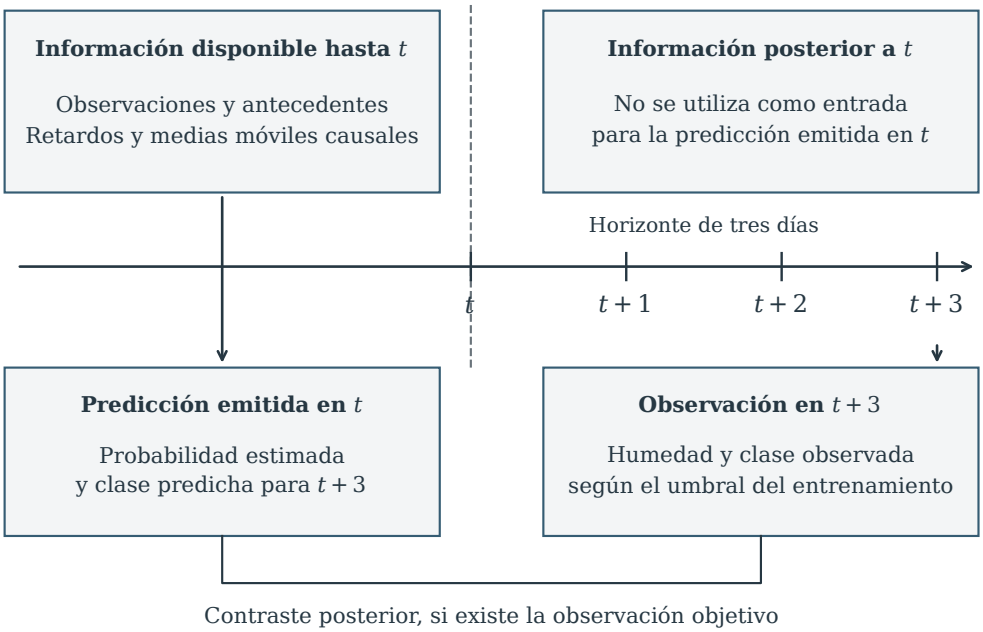


FIGURA 2.1. Relación temporal entre las entradas de la predicción emitida en t y la observación objetivo en $t + 3$.

El percentil del entrenamiento y el umbral de decisión cumplieron funciones distintas. El primero definió qué observaciones se consideraron positivas dentro del problema planteado. El segundo determinó a partir de qué probabilidad se emitió una clasificación positiva. Por lo tanto, una modificación del percentil habría cambiado el significado de la etiqueta, mientras que una modificación del umbral de decisión habría cambiado la conversión de las probabilidades en alertas.

La procedencia se documentó mediante la fuente, la localización, las variables, las unidades, la frecuencia, el rango temporal y una huella SHA-256. La ingesta simulada del prototipo demostró el flujo operativo, pero no integró la evidencia científica. La prueba de concepto física permaneció como extensión opcional, por lo que la contrastación de la hipótesis no dependió de la disponibilidad de hardware.

El uso de fuentes públicas delimitó el alcance de las conclusiones. Las series permitieron estudiar el procedimiento predictivo sobre un conjunto reproducible de observaciones, pero no acreditaron por sí solas su correspondencia con el estado fisiológico de un cultivo particular. La localización identificó el dominio de los datos analizados. No equivalió a una validación realizada con sensores y observaciones agronómicas en una explotación hortícola.

2.3. Preparación y mecanismos de robustez

La preparación produjo una grilla diaria por localización. Se controlaron fechas nulas, duplicadas, frecuencias subdiarias y omisiones no declaradas. Las series se

procesaron por separado para impedir que el final de una localización se transformara en antecedente artificial de otra. Las variables de entrada se imputaron por propagación hacia adelante cuando existía una observación previa válida; la variable objetivo no se imputó.

La representación se construyó a partir de la humedad del suelo, la humedad relativa y la radiación solar, mediante retardos de uno, dos y tres días y medias móviles causales de tres y siete días. Los parámetros estimados durante las transformaciones, incluidos el percentil del objetivo y el detector de anomalías, se calcularon solo con el entrenamiento correspondiente.

Los retardos representaron valores registrados en días anteriores. Las medias móviles resumieron el comportamiento de una ventana reciente y permitieron describir la evolución de las variables sin incorporar observaciones posteriores a la emisión. La continuidad del calendario fue relevante para esta representación: un retardo de tres días debía conservar ese significado temporal y no convertirse en el tercer registro disponible después de omitir fechas.

La propagación hacia adelante utilizó la última observación previa disponible. Este procedimiento evitó completar una entrada con información futura, aunque no convirtió el valor imputado en una medición nueva. La ausencia de la observación necesaria para construir la etiqueta tuvo un tratamiento diferente: no se dedujo un resultado futuro a partir de valores anteriores. Se mantuvo así la distinción entre preparar las entradas y disponer de una referencia para evaluar la predicción.

El control de calidad combinó reglas de dominio y detección no supervisada mediante Isolation Forest [19]. Una observación marcada como anómala no se interpretó automáticamente como un error, ya que podía representar una falla de medición o un episodio ambiental infrecuente. Su exclusión se limitó a configuraciones experimentales explícitas. Los datos sintéticos se generaron únicamente a partir del entrenamiento, conservaron su procedencia y no se incorporaron a la validación ni a la evaluación.

2.4. Diseño experimental y estrategia de modelado

La evaluación comparó una configuración base, una con aumento sintético, otra con detección de anomalías y una configuración completa. Todas compartieron la definición del objetivo, el horizonte y las fechas de evaluación. La escasez se representó mediante una selección distribuida en el entrenamiento y otra concentrada en las observaciones recientes. El ruido se aplicó sobre las variables observadas, sin modificar la humedad utilizada para construir la etiqueta a tres días. Cada fuente de aleatoriedad utilizó una secuencia de semillas independiente.

Las configuraciones permitieron examinar por separado la generación sintética y la detección de anomalías, además de su combinación. La comparación no supuso de antemano que ambas técnicas fueran beneficiosas. Un componente podía conservar información útil, introducir variaciones o excluir observaciones relevantes. Por ello, su aporte se interpretó a partir de las diferencias entre configuraciones evaluadas bajo condiciones comunes.

La escasez se refirió a la cantidad de ejemplos supervisados disponibles para el ajuste. La selección distribuida conservó ejemplos de distintos momentos del entrenamiento, mientras que la selección reciente concentró el mismo presupuesto en su tramo final. Esta distinción permitió estudiar la cantidad y la distribución temporal de los ejemplos sin equipararlas a la desaparición de días del calendario de observaciones.

El ruido representó una perturbación de las variables disponibles para predecir. Mantener sin perturbación experimental la humedad empleada para construir la etiqueta permitió distinguir el deterioro de las entradas de un cambio en la definición del resultado. La intensidad aplicada correspondió a una condición de prueba y no a una caracterización validada de las fallas de un sensor físico.

Se utilizó Random Forest [20] como predictor común a las configuraciones comparadas. Este modelo combinó árboles de decisión y permitió representar relaciones no lineales. Mantener la misma familia de modelo permitió estudiar los mecanismos de aumento sintético y detección de anomalías sin introducir un cambio simultáneo de predictor.

Como alternativas conceptuales para la clasificación, la regresión logística proporciona una referencia lineal e interpretable, mientras que los modelos basados en árboles permiten representar relaciones no lineales. Random Forest combina árboles mediante una estrategia de *bagging*, mientras que HistGradientBoostingClassifier utiliza *boosting* basado en histogramas. Por su parte, un ensamble Soft Voting combina las probabilidades estimadas por distintos clasificadores mediante un promedio, que puede ponderarse con pesos fijos [21, 20, 22, 23].

Esta descripción distingue las características de las alternativas de modelado y no implica que todas hayan formado parte de la evaluación realizada.

Se calcularon el coeficiente de correlación de Matthews (MCC) [24], precisión, exhaustividad, F1, exactitud balanceada, área bajo la curva ROC y precisión promedio [25]. Las configuraciones se compararon con referencias de clase mayoritaria, persistencia y estrés constante. La variabilidad del procedimiento se describió mediante la media y la desviación estándar de las métricas entre semillas, sobre un mismo período de evaluación. Esta dispersión no se interpretó como incertidumbre entre poblaciones independientes.

Las métricas describieron aspectos complementarios de la predicción. La precisión expresó qué proporción de las alertas positivas correspondió a casos positivos observados, mientras que la exhaustividad indicó qué proporción de los casos positivos fue detectada. F1 resumió ambas mediante su media armónica. La exactitud balanceada consideró el reconocimiento de cada clase por separado, mientras que MCC incorporó los aciertos y errores de ambas clases [24, 25].

Para la clasificación binaria, el MCC se expresa mediante la ecuación 2.1 [24, 25]:

$$\mathrm{MCC} = \frac{VP \cdot VN - FP \cdot FN}{\sqrt{(VP + FP)(VP + FN)(VN + FP)(VN + FN)}}. \tag{2.1}$$

En esta expresión, VP y VN representan las cantidades de verdaderos positivos y verdaderos negativos, mientras que FP y FN corresponden a los falsos positivos y falsos negativos. La clase positiva representa la condición de humedad inferior al umbral relativo definido para el problema. Cuando el denominador es distinto de cero, el coeficiente toma valores entre -1 y 1: el valor 1 indica coincidencia

perfecta entre las clases predichas y observadas, 0 indica ausencia de correlación y -1 indica desacuerdo total.

El área bajo la curva ROC y la precisión promedio permitieron examinar la ordenación de las observaciones según la puntuación del modelo a través de distintos umbrales. Su interpretación complementó las métricas calculadas con un umbral de decisión fijo. Las referencias de comparación también aportaron contexto: la clase mayoritaria y el estrés constante mostraron el comportamiento de reglas triviales, mientras que la persistencia utilizó la condición observada como referencia para la predicción [25].

La evaluación de probabilidades también puede abordarse mediante la pérdida logarítmica y la puntuación de Brier [26]. La primera penaliza las probabilidades asignadas a los resultados observados, con una penalización elevada ante predicciones incorrectas de alta confianza. La segunda cuantifica la diferencia cuadrática entre la probabilidad estimada y el resultado observado. Ambas complementan las métricas de clasificación y de ordenación, aunque no deben interpretarse por sí solas como medidas exclusivas de calibración [25].

El *moving block bootstrap* permite remuestrear bloques de observaciones consecutivas para conservar parte de la dependencia temporal de la serie [27, 28]. En su aplicación a una comparación pareada, cada réplica utiliza los mismos índices temporales para los resultados observados y las predicciones de ambos modelos, y recalcula la diferencia entre sus métricas. Este procedimiento se distingue de la dispersión entre semillas: el remuestreo modifica la composición de las observaciones evaluadas, mientras que las distintas semillas describen la variabilidad del procedimiento sobre un período común. Su presentación aquí corresponde al fundamento metodológico, no a una estimación ejecutada en la evaluación descrita.

2.5. Retroalimentación, reproducibilidad y validez

La retroalimentación humana se incorporó después de la emisión. Cada pronóstico conservó sus fechas de emisión y objetivo, la probabilidad, el umbral y la identidad del predictor. La recalibración utilizó solo observaciones cuyo resultado al final del horizonte ya se encontraba disponible y validaciones posteriores a esa fecha. Para cada evento se registró el vínculo entre el predictor de origen, las referencias incorporadas y el predictor sucesor, junto con la versión y la huella del contenido utilizado.

La intervención humana no se consideró una garantía de mejora. Las correcciones podían contener errores, diferencias de criterio o contexto insuficiente. Por ello, se preservó su procedencia y se exigió una evaluación posterior antes de atribuir cambios de desempeño al mecanismo *human-in-the-loop*.

Capítulo 3

Diseño e implementación

En este capítulo se describen la arquitectura de la solución y la implementación de sus componentes. Se presentan el procesamiento de observaciones, la generación de alertas, la retroalimentación humana y las decisiones de almacenamiento y despliegue. También se explican los controles incorporados para conservar la trazabilidad y tratar las inconsistencias.

3.1. Arquitectura de la solución

La solución se organizó en tres partes: una interfaz para consultar observaciones y revisar alertas, un servicio de aplicación para procesar las solicitudes y un conjunto de recursos de almacenamiento para conservar datos y modelos. Las responsabilidades se distribuyeron de modo que la presentación pudiera modificarse sin alterar las reglas de predicción.

La figura 3.1 presenta los componentes y sus relaciones. La interfaz web envía las solicitudes del usuario al servicio de aplicación, denominado backend. Este servicio coordina la ingesta, la preparación de datos y la predicción para generar las alertas. También recibe las revisiones humanas utilizadas en la actualización del modelo. Estas funciones se implementaron como módulos en Python dentro de una misma aplicación.

La información se conserva según su función. Las observaciones y las revisiones humanas se almacenan en archivos locales. En la aplicación base, MLflow gestiona el registro de modelos y permite identificar y recuperar las versiones del predictor. Para ello, utiliza PostgreSQL como almacenamiento de la información descriptiva y MinIO para los archivos de los modelos. La identificación de versiones permite relacionar cada alerta con el predictor que la produjo.

El despliegue se organizó mediante Docker Compose, que reunió las aplicaciones necesarias y definió sus conexiones y ubicaciones de almacenamiento. Los datos persistentes se mantienen separados de los procesos en ejecución para conservarlos ante reinicios. En la figura, los contornos punteados delimitan los servicios, los cilindros representan almacenamientos y las flechas indican intercambios de información. Las tecnologías y las decisiones de implementación se explican después de la figura.

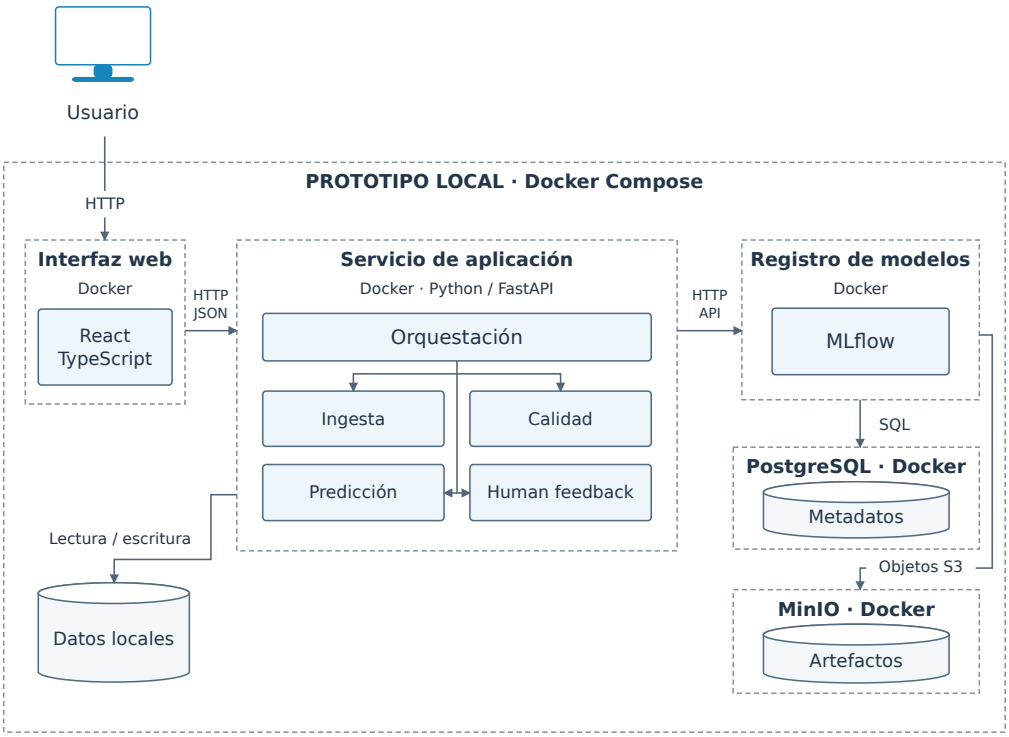


FIGURA 3.1. Arquitectura de la aplicación base y despliegue con Docker.

3.2. Implementación de los módulos de la aplicación

Esta sección presenta las responsabilidades de los módulos y el recorrido de la información desde la recepción de observaciones hasta la revisión de las alertas. La descripción distingue las operaciones de consulta, predicción y actualización del modelo.

3.2.1. Interfaz de consulta y servicio de aplicación

La interfaz se implementó como una aplicación web con React y TypeScript. Su función es presentar el estado de las observaciones, los pronósticos y las acciones disponibles para el usuario. También incorpora consultas sobre la calidad de los datos y la versión del predictor utilizado. Estas consultas permiten observar las entradas y el contexto de cada alerta.

El backend se implementó con FastAPI. La interfaz se comunica con este servicio mediante solicitudes HTTP e intercambia información en formato JSON, una representación estructurada de los datos. Ante una solicitud de pronóstico, el backend recupera las observaciones necesarias, coordina su procesamiento y devuelve el resultado a la interfaz.

Las decisiones de modelado se concentran en el backend: el cálculo del umbral del objetivo, el ajuste de los modelos y la comprobación de las condiciones necesarias para predecir. La interfaz solicita las operaciones y presenta sus respuestas, sin intervenir en esos cálculos.

La revisión de alertas y la recalibración también requieren solicitudes explícitas desde la interfaz. Cada solicitud incluye las referencias necesarias para identificar la observación y la operación. La inferencia, entendida como la aplicación de un modelo ajustado a las observaciones para obtener una predicción, se ejecuta dentro del backend.

3.2.2. Ingesta y preparación de observaciones

El módulo de ingesta recibe observaciones y las organiza para su posterior consulta. Se estableció que cada observación conservara su fecha, la localización o serie correspondiente y los valores de las variables disponibles. Esta estructura permite reconstruir una secuencia temporal y evita tratar como equivalentes datos pertenecientes a lugares o momentos diferentes.

La ingesta del prototipo contempló un recorrido de demostración con entradas simuladas. Su propósito fue verificar la recepción y el procesamiento de observaciones sin depender de un sensor físico. Esta capacidad no convirtió los datos simulados en evidencia científica ni acreditó un despliegue en campo.

El módulo de preparación y calidad evalúa si las observaciones cumplen las condiciones requeridas para su procesamiento. Para ello, incorpora reglas de validación, transformaciones y detección de anomalías. La detección de un valor atípico permite señalar una observación para su análisis, pero no se interpreta automáticamente como un error: un valor infrecuente también puede corresponder a una condición ambiental real.

La detección de anomalías se implementó con Isolation Forest, de scikit-learn. Este modelo identifica observaciones atípicas sin requerir etiquetas previas de anomalía. Su ajuste se separó de su aplicación para permitir el uso del detector sobre nuevas observaciones sin volver a entrenarlo. Esta función está disponible en el módulo de calidad, pero permanece desactivada en el pronóstico de la interfaz.

La separación por serie permite mantener la correspondencia entre los datos consultados y el pronóstico solicitado. La aplicación identifica la serie antes de cargar su historial. Esta decisión permite que la interpretación de una alerta conserve el contexto de las observaciones que la originaron.

Los módulos comparten las operaciones de lectura y escritura de observaciones. De este modo, la preparación de datos y la predicción utilizan un acceso uniforme al historial, sin resolver por separado la apertura de los archivos.

Los controles temporales se incorporaron a la preparación de los datos de entrenamiento. Se conservaron la fecha de emisión y la fecha de la observación futura utilizada para definir cada etiqueta. Al delimitar los conjuntos de entrenamiento y evaluación, se excluyeron del ajuste los ejemplos cuya fecha objetivo alcanzaba el período reservado para evaluar. Así se evitó incorporar resultados futuros al entrenamiento a través de las etiquetas, aunque las variables de entrada correspondieran a días anteriores.

Los parámetros de las transformaciones se estimaron únicamente con los datos de entrenamiento y se mantuvieron al procesar los datos de evaluación. Junto con el predictor se conservaron el umbral utilizado para definir la variable objetivo y el detector de anomalías, una vez que este se hubo habilitado y ajustado. Durante

la inferencia se recuperan estos elementos, sin calcular nuevamente el umbral ni volver a ajustar el detector en cada solicitud.

La generación de datos sintéticos se mantiene dentro del procesamiento de entrenamiento y separada de las observaciones utilizadas para evaluar. Su incorporación respeta la restricción metodológica presentada en el capítulo anterior y no forma parte de cada consulta de pronóstico en la interfaz.

3.2.3. Modelado predictivo y generación de alertas

El módulo predictivo recibe observaciones preparadas y construye la representación utilizada por el modelo. La representación combina el estado actual con antecedentes temporales para describir el nivel de humedad y su evolución reciente. El modelo utiliza esa información para estimar una condición futura desde la fecha de emisión.

La configuración base de la aplicación utiliza Random Forest, implementado con scikit-learn. El modelo recibe la representación temporal de las observaciones y produce probabilidades para las clases del objetivo. La aplicación separa su ajuste de su utilización posterior para emitir pronósticos.

El módulo predictivo también incorporó la regresión logística como candidata. Ambos modelos comparten las operaciones de ajuste y predicción de scikit-learn. El pronóstico web utiliza Random Forest, mientras que la implementación destinada a la comparación experimental incluye, además, HistGradientBoostingClassifier y un ensamble Soft Voting. Estos ámbitos se mantienen diferenciados: la disponibilidad de un candidato experimental no implicó su habilitación en la interfaz. La integración del ensamble en un recorrido operativo separado se describe en la sección 3.10.

HistGradientBoostingClassifier (HGB) se incorporó mediante un constructor que recibió la configuración del modelo, incluidos la tasa de aprendizaje, el número de iteraciones y los límites de complejidad de los árboles. La implementación expone las operaciones de ajuste y obtención de probabilidades necesarias para utilizarlo como candidato en el procedimiento experimental.

El ensamble Soft Voting se implementó mediante una combinación propia de regresión logística, Random Forest e HistGradientBoostingClassifier. El procedimiento ajusta cada componente y combina sus probabilidades con pesos fijos iguales de un tercio. La combinación conserva por separado la configuración de cada modelo y su tratamiento del desbalance de clases. Estos pesos de combinación tienen una función distinta de los pesos asignados a las observaciones durante el entrenamiento.

La tabla 3.1 resume el ámbito de integración de los modelos en la aplicación base y en los componentes experimentales. El recorrido operativo del ensamble se presenta por separado en la sección 3.10. Describe componentes implementados, sin atribuir resultados a una evaluación científica pendiente ni establecer una superioridad de desempeño entre candidatos.

TABLA 3.1. Modelos de la aplicación base y de los componentes experimentales.

Modelo	Integración
Regresión logística	Candidata predictiva y experimental
Random Forest	Pronóstico web y candidato experimental
HGB	Candidato experimental
Soft Voting	Ensamble experimental
Isolation Forest	Calidad de datos. Inactivo en el pronóstico web

La salida se expresa como una probabilidad asociada al objetivo operacional definido en la metodología. A partir de esa probabilidad se obtiene una clase mediante un umbral de decisión. La salida conserva el alcance definido en el capítulo 2: una alerta relativa a la humedad del suelo, sin convertirla en una prescripción de riego o en un diagnóstico fisiológico del cultivo.

El predictor está asociado a las variables de entrada y al horizonte de predicción para los que se ajustó. Estas condiciones definen su contrato de uso. Antes de aplicarlo, se comprueba que las observaciones preparadas respeten la representación esperada. La verificación impide utilizar un modelo con entradas incompatibles.

Cada salida conserva la identidad del predictor que la produce. Una recalibración puede cambiar el modelo utilizado en nuevas consultas. La identificación de la versión de origen permite interpretar las alertas históricas con independencia del modelo activo.

La emisión de una predicción exige un historial suficiente. Cuando faltan las observaciones necesarias, la solicitud devuelve un mensaje de error. La ausencia de información se comunica como una limitación del procesamiento, sin interpretarla como una condición favorable del cultivo.

Cada pronóstico conserva su fecha de emisión, la fecha a la que se refiere la predicción, la probabilidad y la identidad del modelo. La distinción entre ambas fechas permite reconocer cuándo se dispuso de la información de entrada y cuándo corresponde observar el resultado. Estos datos también proporcionan las referencias necesarias para la revisión humana posterior.

En la aplicación base se preserva una única alerta emitida por serie y día. Una nueva solicitud no reemplaza la predicción histórica por la salida de otro modelo. Esta decisión protege la correspondencia entre la alerta presentada y la revisión del usuario, especialmente cuando el predictor disponible cambia después de una recalibración.

3.2.4. Retroalimentación humana y recalibración

El módulo de retroalimentación humana, o *human feedback*, se implementó mediante un registro de revisiones asociado a las alertas. El usuario puede confirmar o rechazar una salida desde la interfaz. La revisión se conserva junto con las referencias necesarias para identificar la observación y el predictor de origen. Así, la intervención humana queda registrada de forma persistente.

La selección de revisiones para recalibrar respeta el horizonte de predicción. El resultado futuro de una alerta a tres días aún no está disponible en la fecha de

emisión. Por ello, se utilizan observaciones cuyo resultado ya puede conocerse y revisiones compatibles con esa disponibilidad temporal.

La recalibración se implementó como una operación explícita iniciada desde la interfaz. La acumulación de revisiones no sustituye por sí sola al modelo. Ante una solicitud de recalibración, el backend selecciona las observaciones elegibles y ejecuta el procedimiento. El resultado se registra como una nueva versión, vinculada con el predictor anterior y con la información utilizada.

La relación entre versiones se denomina linaje y permite reconstruir la procedencia de un predictor a partir del modelo anterior y de las revisiones utilizadas para actualizarlo. Este registro documenta la actualización, pero no demuestra una mejora de desempeño. La comprobación de esa mejora requiere una evaluación con información independiente de la utilizada para recalibrar.

La incorporación de revisiones al entrenamiento se limita a las alertas rechazadas que cuentan con una etiqueta corregida. La confirmación de una alerta permite registrar la valoración del usuario, pero no se trata como una corrección de la etiqueta. Esta distinción evita confundir el registro de una revisión con una modificación efectiva del conjunto utilizado para ajustar el modelo.

Antes de aplicar una corrección se comprueba su compatibilidad con el predictor de origen, el horizonte y el umbral de referencia. Una revisión asociada a otro contexto no se incorpora de manera automática. Si la información requerida resulta insuficiente o contradictoria, el procedimiento informa la causa e impide continuar con la actualización.

La recalibración se realiza mediante el ajuste de una copia del modelo sobre las observaciones elegibles. Se conservan la familia del modelo y sus parámetros de configuración, y se actualizan los valores aprendidos. El conjunto utilizado incorpora las nuevas etiquetas corregidas y las correcciones de ciclos anteriores. Este procedimiento permite acumular las revisiones válidas sin perder las decisiones humanas ya utilizadas.

La actualización exige la existencia de correcciones nuevas y de información suficiente para representar ambas clases. También se comprueba que el historial permita recuperar las observaciones correspondientes a todas las correcciones conservadas. Estas condiciones evitan presentar como una nueva recalibración una operación sin cambios pendientes o con antecedentes incompletos.

La fecha hasta la que el modelo ha incorporado información de entrenamiento se conserva junto con la nueva versión. Este dato permite interpretar el alcance temporal de cada predictor. La actualización del modelo no modifica la identidad de las alertas emitidas anteriormente, que permanecen asociadas a su versión de origen.

3.3. Registro de modelos y conservación de la información

En la aplicación base, MLflow se utiliza para registrar las versiones del modelo y recuperarlas desde el backend. La carga de paquetes operativos del ensamble sigue una modalidad diferente, descrita en la sección 3.11. El registro conserva los antecedentes necesarios para distinguir un predictor de sus actualizaciones y relacionarlo con las revisiones aplicadas.

Las observaciones y las revisiones humanas se conservan en archivos persistentes accesibles por la aplicación. La información descriptiva de las versiones, o metadatos, se almacena en PostgreSQL a través de MLflow. MinIO conserva los archivos asociados, incluidos los modelos ajustados. Esta distribución separa los datos de la aplicación de los recursos necesarios para recuperar un predictor.

La conservación de estos registros permite retomar el funcionamiento del prototipo y consultar antecedentes después de un reinicio. La persistencia se resuelve mediante las ubicaciones de almacenamiento descritas en la sección de despliegue.

3.3.1. Identificación de versiones y antecedentes

Para cada actualización se conservan las referencias a la versión de origen, la versión resultante y las revisiones aplicadas. Esta información permite consultar la secuencia de cambios y reconocer el modelo activo sin depender de nombres de archivo elegidos manualmente.

La recuperación de una versión registrada incluye la comprobación del contrato de uso descrito en la subsección 3.2.3. La presencia de un archivo de modelo no basta para utilizarlo: sus variables y su horizonte deben corresponder a los del pronóstico solicitado.

Cuando hay un predictor registrado compatible, la aplicación lo recupera para emitir nuevas predicciones. En los casos en los que todavía no hay un predictor registrado, utiliza la configuración base prevista para el pronóstico. Este comportamiento permite reutilizar los modelos ajustados y conservar el efecto de una recalibración en las consultas posteriores.

La carga de antecedentes distingue dos situaciones. Un registro histórico sin declaración de linaje puede conservarse, aunque no se presenta como una cadena completa de versiones. En cambio, si un evento declara disponer de linaje, la ausencia o incompatibilidad de sus referencias produce un error. La conservación de un registro histórico no autoriza su reutilización cuando incumple el contrato de uso de la aplicación.

3.3.2. Correspondencia entre los datos y la actualización

Las series de observaciones se almacenan en formato Parquet, que permite conservar datos tabulares y recuperarlos para el procesamiento. Las operaciones comunes de lectura y escritura mantienen el tratamiento de los archivos separado de la lógica de predicción.

Los datos utilizados en una recalibración se identifican mediante una huella calculada a partir del contenido del archivo. Esta huella permite reconocer el conjunto que dio origen a la actualización. Su función es registrar la procedencia de los datos, sin valorar la calidad de las observaciones.

La lectura de las observaciones y el cálculo de esa huella se realizan sobre una misma captura del archivo. De este modo, el registro de procedencia corresponde a los datos efectivamente entregados al procedimiento. Si el archivo cambia durante la lectura, la operación se interrumpe para evitar una actualización asociada a información inconsistente.

3.3.3. Registro de las condiciones de ejecución

La conservación de versiones permite distinguir las actualizaciones operativas de la evidencia utilizada para evaluar el sistema. Cada ejecución registra la configuración, las semillas que controlan los procedimientos aleatorios, las fechas de separación de los datos y las versiones del entorno de software. Las predicciones y las métricas se conservan junto con esas referencias para relacionar los resultados con las condiciones que los produjeron.

La evidencia formal obtenida se mantuvo separada de las mejoras posteriores de la interfaz y de la trazabilidad. Una modificación de la presentación o del registro de antecedentes no reemplazó los resultados ya conservados. Esta decisión permitió continuar el desarrollo sin atribuir a una ejecución anterior características incorporadas después.

3.4. Despliegue de la aplicación con Docker

El prototipo se desplegó mediante contenedores Docker coordinados con Docker Compose. Se definieron servicios para la interfaz, el backend, MLflow, PostgreSQL y MinIO, junto con un servicio auxiliar para preparar el almacenamiento de artefactos. Esta organización permitió describir de manera conjunta qué aplicaciones debían iniciarse, cómo se relacionaban y dónde conservarían su información.

Cada contenedor reúne una aplicación y sus dependencias de ejecución. La interfaz, o frontend, utiliza Node y Vite, mientras que el backend utiliza Python y Uvicorn para atender las solicitudes a través de su interfaz de programación (API). Esta separación permite ejecutar el prototipo sin instalar todas esas tecnologías directamente en el equipo de demostración y reconstruir un servicio sin reorganizar las dependencias de los restantes.

Los volúmenes proporcionan persistencia a PostgreSQL y MinIO. El backend utiliza, además, un directorio de datos montado desde el equipo anfitrión. Un volumen puede entenderse como una ubicación de almacenamiento que permanece disponible aunque el contenedor se detenga o se vuelva a crear. Esta característica permite conservar modelos, observaciones y revisiones durante la evolución del prototipo.

La configuración se orientó a una demostración local. Docker resolvió la organización de los entornos de ejecución y sus conexiones. La alta disponibilidad, el escalamiento y el funcionamiento productivo continuo quedaron fuera del alcance de este despliegue.

3.5. Consulta del estado y tratamiento de incidencias

La interfaz permite consultar la calidad de los datos, el predictor activo y su historial de actualizaciones sin inspeccionar archivos internos. Estas consultas no inician ajustes. La generación de pronósticos y la recalibración requieren solicitudes específicas, separadas de las consultas de estado.

El tratamiento de las incidencias se organiza según la operación solicitada y la condición incumplida. La tabla 3.2 resume los controles de predicción y retroalimentación. En todos los casos, la aplicación informa la causa que impide continuar.

TABLA 3.2. Controles previos a la ejecución.

Operación	**Condición detectada**	**Respuesta**
Procesamiento	Datos ausentes	Impedir el inicio
Pronóstico	Historial insuficiente	No emitir alerta
Recalibración	Revisión incompatible	Rechazar la actualización
Recalibración	Sin correcciones nuevas o antecedentes suficientes	No actualizar ni registrar una versión

Una alerta negativa expresa una clasificación del modelo, mientras que un error de procesamiento indica que la solicitud no ha podido resolverse. La aplicación mantiene esa diferencia para que la ausencia de una predicción no se interprete como ausencia de riesgo.

La consulta de alertas históricas preserva el registro original y su correspondencia con las revisiones humanas. Si falta información temporal para interpretarlo, la aplicación informa la inconsistencia sin completar los campos con valores de un pronóstico nuevo.

En la evaluación, las métricas indeterminadas por ausencia de alguna clase se conservaron sin sustituirlas por cero o por valores favorables. Así se distinguió la falta de un resultado evaluable del desempeño del modelo. Este control no implicó mostrar todas las métricas en la interfaz.

Las pruebas automatizadas comprobaron las respuestas del software ante entradas incompletas o incompatibles. Su función fue verificar las reglas implementadas. Estas pruebas no sustituyeron la evaluación del desempeño predictivo ni acreditaron una validación agronómica en campo.

3.6. Contratos de intercambio y recuperación del contexto

La consulta histórica comprende dos recorridos con propósitos diferentes. El primero permite examinar las predicciones conservadas de una evaluación experimental y contrastarlas con las observaciones posteriores. El segundo permite demostrar el funcionamiento del ensamble mediante predicciones preparadas sobre datos históricos de distintos sitios. Ambos conservan las predicciones durante la consulta, pero utilizan registros y reglas de intercambio diferentes. Las secciones 3.6 a 3.9 describen el primer recorrido. El funcionamiento del ensamble se presenta desde la sección 3.10.

Las responsabilidades de los módulos, presentadas en la sección 3.2, se concretaron mediante contratos de intercambio. Estos contratos establecen qué información debe recibir cada operación y qué datos debe devolver el servicio de aplicación. Su propósito es conservar el contexto necesario para interpretar una predicción, tanto durante su consulta inicial como en revisiones posteriores.

El servicio de aplicación separa la recepción de solicitudes, el procesamiento y el acceso a los registros. La interfaz de programación valida los datos recibidos y organiza las respuestas. Los componentes de procesamiento aplican las reglas de cada operación, mientras que los de almacenamiento recuperan o conservan la información. Esta distribución permite mantener las reglas de funcionamiento independientes de la pantalla utilizada para consultar los resultados.

En la reproducción de la evaluación histórica, el servidor recupera un conjunto de archivos que reúne los datos y las predicciones conservadas. La configuración de la aplicación determina qué conjunto puede consultarse. El usuario no selecciona libremente archivos ni ejecuciones experimentales. Antes de habilitar la consulta, el servicio comprueba la integridad de los archivos y su autorización de uso. Si faltan o resultan inválidos, informa que no están disponibles, sin generar una predicción nueva para reemplazarlos.

La información devuelta para cada predicción incluye las fechas de origen y objetivo, la identificación de la ejecución experimental, su configuración, la semilla y el horizonte. La semilla identifica la configuración utilizada para controlar los procedimientos aleatorios. Los resultados observados se muestran según la fecha simulada de consulta. La información general de la ejecución permite recuperar la fuente de datos, las condiciones de procesamiento y la regla utilizada para definir la clase.

La identificación de la ejecución y las referencias de la predicción cumplen funciones complementarias. La primera permite reconocer el experimento del que procede el resultado. La fecha de origen sitúa la predicción dentro de esa ejecución, mientras que el horizonte y la fecha objetivo indican cuándo corresponde contrastarla. Una fecha aislada no basta para relacionar resultados de distintas ejecuciones o series de observaciones.

El servicio distingue la clase predicha de la confianza que pueda atribuirse al resultado. Aunque los archivos conservan la salida numérica del clasificador, la consulta histórica no la presenta como una probabilidad de riesgo ni como un porcentaje de confianza. La calibración de esa salida no se ha acreditado para la ejecución reproducida. Por ello, se comunican la clase archivada y las condiciones necesarias para interpretarla.

3.7. Reproducción histórica y disponibilidad temporal

La reproducción histórica permite consultar una predicción conservada y contrastarla con información posterior. Se utiliza una ejecución experimental previamente registrada sobre datos de Melchor Romero, con un horizonte de tres días. El servicio recupera sus resultados archivados. Por ello, avanzar o retroceder el reloj simulado no inicia un entrenamiento ni vuelve a ejecutar el modelo. La predicción consultada permanece fija durante el recorrido.

El reloj simulado determina qué información puede devolver el servicio en cada consulta. Antes de la fecha de origen, la predicción no está disponible en la reproducción. Una vez alcanzado el origen, se habilita la consulta de la clase predicha y de su fecha objetivo. Cuando el reloj alcanza esta última, puede revelarse el resultado posterior, siempre que esté registrado como observado. Alcanzar una fecha habilita la consulta del resultado, pero no crea una observación inexistente.

La misma restricción se aplica al historial de humedad. El servidor selecciona únicamente registros cuya fecha es anterior o igual al reloj simulado. Los registros posteriores quedan fuera de la respuesta. La restricción no depende de ocultar visualmente datos que ya hayan sido enviados al navegador. Este criterio permite que la información disponible durante el recorrido responda a una regla temporal común, tanto para la serie consultada como para el resultado de la predicción.

Al retroceder el reloj, la observación posterior vuelve a quedar fuera de la respuesta y la revisión asociada deja de estar visible si la fecha simulada es anterior a la fecha objetivo. Los archivos originales y las revisiones registradas no se eliminan por esa operación. La variación afecta la información expuesta en la consulta, mientras que la evidencia conservada permanece disponible para reconstruir el recorrido.

La disponibilidad de información durante la consulta se distingue de la validez temporal del entrenamiento. Ocultar observaciones futuras no demuestra que el modelo original se haya ajustado sin utilizarlas. Por ello, el servicio verifica por separado las fechas declaradas de entrenamiento y comprueba que las fechas objetivo de sus ejemplos sean anteriores al corte entre entrenamiento y evaluación. También verifica que las fechas de origen de las predicciones no precedan el corte autorizado. Estos controles complementan la restricción de visibilidad, sin sustituir la revisión del procedimiento experimental.

La tabla 3.3 distingue las referencias temporales del recorrido. En particular, el corte de la partición no se interpreta como la última fecha utilizada para entrenar. La visibilidad de una observación depende del reloj simulado, mientras que su admisión para el ajuste requiere controles independientes.

TABLA 3.3. Referencias temporales de la reproducción histórica.

Referencia	**Función en el recorrido**
Fecha de corte	Delimita los períodos de entrenamiento y evaluación.
Última fecha de entrenamiento	Identifica el último ejemplo incluido en el ajuste. Su fecha objetivo debe ser anterior al corte.
Fecha de origen	Sitúa la predicción archivada dentro de la ejecución experimental.
Fecha objetivo	Indica el día al que se refiere la predicción.
Reloj simulado	Determina qué registros y resultados posteriores puede devolver la consulta.
Fecha real de revisión	Registra cuándo se ingresó la revisión, sin atribuirla al período histórico.

Los archivos consultados reúnen una copia de los datos, las predicciones, la configuración y la información descriptiva de la ejecución. El servicio comprueba sus huellas de contenido, utilizadas para detectar diferencias respecto de los archivos declarados, y la correspondencia entre sus identificadores. La consulta se restringe al conjunto de resultados previamente revisado y autorizado mediante una configuración externa a esos archivos. Una declaración de validez incluida en ellos no basta para habilitar su uso. Esta restricción permite reproducir un caso identificado, sin atribuir al servicio la capacidad de validar cualquier experimento.

El recorrido mantuvo su carácter retrospectivo. Las predicciones procedieron de una evaluación histórica y no de emisiones efectuadas por un sistema desplegado durante aquel período. La disponibilidad diaria de las entradas constituyó un supuesto documentado del protocolo, sin una marca de recepción verificada para cada observación. Estas condiciones delimitaron la interpretación temporal de la demostración, que no acreditó un funcionamiento productivo en campo.

3.8. Procedencia de las observaciones y valores derivados

Para interpretar una discrepancia entre una predicción y una observación posterior es necesario identificar la procedencia del dato consultado. Un valor conservado en la fuente y otro completado mediante imputación no aportan el mismo tipo de evidencia. El historial incorpora un estado para cada fecha y mantiene separados el dato original, el valor derivado y la explicación de su procedencia. Esta distinción amplía la información disponible para interpretar el resultado sin modificar los registros originales.

La tabla 3.4 resume los estados del historial. Los marcadores de imputación indican si un valor faltante ha sido completado. Cuando existe un valor original, este tiene prioridad sobre esos marcadores. Ante su ausencia, el servicio distingue los valores imputados, los datos ausentes en la fuente y los casos cuya condición no puede determinarse. La falta de información no se convierte en una medición ni en una clase predictiva.

TABLA 3.4. Estados de procedencia de las observaciones en el historial.

Estado	Condición	Información conservada
Medida	Existe un valor original en la fuente.	Valor original, que no se sustituye por una estimación.
Imputada	Falta el original y el marcador identifica una imputación causal.	Dato original ausente. Valor derivado separado y causa de imputación.
Sin dato en la fuente	Falta el original y el marcador no identifica una imputación.	Ausencia del valor y causa explícita.
No determinado	Falta el original y no hay evidencia suficiente para clasificar la ausencia.	Ausencia del valor y explicación de la indeterminación.

La categoría denominada Medida identifica la presencia de un valor original en la fuente utilizada. No implica necesariamente una lectura directa de un sensor instalado en el cultivo ni asegura por sí sola la calidad o representatividad del dato. En los casos imputados, se conserva la ausencia del original y se presenta por separado el valor reconstruido.

Los marcadores de imputación se reconstruyeron a partir de la copia verificada de los datos y del procedimiento que completó los valores con información previa disponible. Se generaron después de la ejecución experimental, por lo que no formaron parte de sus registros originales. Antes de atribuir un estado, se comprobó

que el código de reconstrucción fuera compatible con el procedimiento previsto. Así se distinguieron los resultados históricos de la información calculada posteriormente para interpretarlos.

La separación entre valores originales y derivados permite reconocer si el contraste utiliza una observación de la fuente o un valor reconstruido. La ausencia de una observación no proporciona una base para confirmar ni rechazar la predicción. Estas situaciones se conservan sin asignar una clase a los datos faltantes ni interpretar la incertidumbre sobre su procedencia como un resultado del modelo.

Los estados del historial describen la procedencia y disponibilidad de los datos. No representan clases predictivas ni un diagnóstico de estrés hídrico. La regla de clasificación de baja humedad mantiene su propia variable, unidad y umbral. De este modo, el origen de una observación se distingue de su relación con el evento predicho. La información de procedencia está disponible en las respuestas del servicio de reproducción de la evaluación histórica. Su presentación en el recorrido del ensamble se describe en la sección 3.13.

3.9. Persistencia y trazabilidad del feedback

El registro de retroalimentación requiere conservar la relación entre la predicción original y la intervención posterior, incluso cuando varias solicitudes acceden al almacenamiento. El mecanismo de recalibración ya descrito en la subsección 3.2.4 se mantiene diferenciado de esta responsabilidad. El almacenamiento permite recuperar las revisiones y sus referencias, pero no acredita que las correcciones se hayan utilizado para actualizar el modelo.

En la reproducción histórica, el servidor admite una revisión únicamente para una predicción existente y después de revelar una observación disponible. El registro conserva la identificación de la ejecución experimental y la fecha de origen de la predicción, junto con la valoración del usuario, la etiqueta corregida, si corresponde, y su comentario. También distingue la fecha real de registro de la fecha simulada de consulta. Por ello, una revisión ingresada durante la demostración no se presenta como una intervención realizada en el período histórico.

Las revisiones de demostración se almacenan por separado de los archivos de la evaluación y del registro operativo. Se agrupan según el conjunto de resultados consultado y la sesión de demostración en la que se registran. Esta organización permite conservarlas sin alterar los archivos originales. Las revisiones documentan la interacción con las predicciones archivadas y no se transfieren al procedimiento de recalibración del modelo operativo.

Cuando varias solicitudes intentan actualizar un mismo registro, es necesario coordinar su acceso para evitar la pérdida de cambios. Sin esa coordinación, dos solicitudes podrían leer la misma versión y guardar modificaciones que sobrescribieran una de las revisiones. En la aplicación base, la protección abarca la lectura, la modificación y la escritura del registro. El archivo actualizado sustituye al anterior de forma completa, sin dejar una versión parcialmente escrita.

La figura 3.2 sintetiza la consulta de una predicción archivada, la disponibilidad temporal de la observación posterior y el registro separado de su revisión.

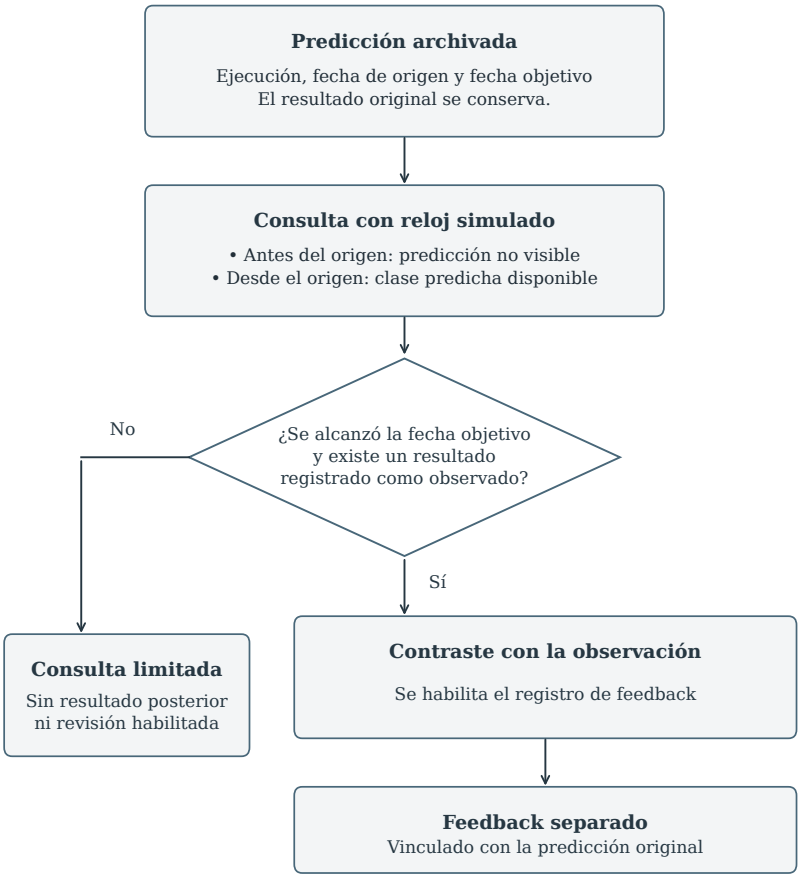


FIGURA 3.2. Recorrido de reproducción histórica y registro de feedback.

El mismo mecanismo permite crear el registro inicial e incorporar nuevas predicciones sin modificar las predicciones y revisiones ya conservadas. En la reproducción histórica, las revisiones se añaden como registros sucesivos y también se coordina su escritura. Cada modalidad de almacenamiento preserva así la relación entre la predicción y las intervenciones posteriores.

La coordinación se aplica únicamente a las actualizaciones realizadas mediante el mismo mecanismo y sobre la misma ubicación de almacenamiento. Los cálculos predictivos y las operaciones de registro de modelos quedan fuera de esa protección. El mecanismo tampoco resuelve desacuerdos entre usuarios ni establece una garantía de coordinación entre servidores independientes.

Las pruebas de software comprobaron la conservación de los registros ante solicitudes simultáneas, creación inicial y superposición de fechas. También verificaron las reglas de visibilidad temporal y procedencia. Estas comprobaciones evaluaron el funcionamiento de los mecanismos implementados, sin demostrar precisión predictiva ni mejoras posteriores a la recalibración.

3.10. Integración del ensamble predictivo

La integración operativa del ensamble permite reunir las salidas de tres familias de clasificadores en una decisión por horizonte. Se utilizan regresión logística,

Random Forest e HistGradientBoostingClassifier, con modelos específicos para uno, dos y tres días. Esta organización separa dos dimensiones del pronóstico: la diversidad de los modelos utilizados para un mismo objetivo y la distancia temporal hasta la observación que debía anticiparse.

A diferencia de la combinación experimental descrita en la subsección 3.2.3, este recorrido utiliza modelos previamente ajustados y almacenados junto con los elementos necesarios para aplicarlos. Cada componente incluye un modelo y un calibrador, encargado de transformar la salida del clasificador para obtener la estimación de probabilidad utilizada por el ensamble. Durante la consulta se aplican estos elementos sin volver a ajustarlos. Esta operación se distingue de la recalibración mediante revisiones humanas, que implica un nuevo ajuste del predictor. La presencia de un calibrador no acredita por sí sola la calidad de las probabilidades en cualquier sitio o período.

Para un horizonte h, la decisión se calcula a partir del promedio de las tres salidas, con pesos iguales de un tercio. La ecuación 3.1 resume esta operación:

$$\bar{p}_h = \frac{p_{\mathrm{LR},h} + p_{\mathrm{RF},h} + p_{\mathrm{HGB},h}}{3}. \tag{3.1}$$

En esta expresión, $p_{\mathrm{LR},h}$, $p_{\mathrm{RF},h}$ y $p_{\mathrm{HGB},h}$ representan las salidas de los componentes de regresión logística, Random Forest e HistGradientBoostingClassifier para el mismo horizonte. Se emite una alerta cuando $\bar{p}_h$ es mayor o igual que $0{,}5$. Este umbral de decisión se mantiene separado del umbral de humedad que define la clase objetivo.

El número de componentes con una salida mayor o igual que $0{,}5$ se conserva como indicador de acuerdo. Esta cantidad no determina la alerta conjunta, ya que el promedio también depende de la magnitud de cada salida. Por ello, dos votos positivos no implican necesariamente una alerta del ensamble. De manera equivalente, una sola salida suficientemente elevada puede situar el promedio por encima del umbral. La tabla 3.5 presenta dos ejemplos ilustrativos, sin atribuirlos a observaciones o resultados experimentales. Los promedios se presentan redondeados a cuatro decimales.

TABLA 3.5. Ejemplos ilustrativos de decisión conjunta y votos positivos.

Salidas de los componentes	**Promedio**	**Votos positivos**	**Alerta conjunta**
0,51/0,51/0,01	0,3433	2 de 3	No
0,99/0,49/0,49	0,6567	1 de 3	Sí

El servicio conserva por separado la decisión conjunta, las salidas individuales y el grado de acuerdo. La disponibilidad de una probabilidad calculada mediante un calibrador no habilita automáticamente su presentación como porcentaje de riesgo al usuario. El cálculo interno y la información autorizada para su presentación se mantienen diferenciados.

Los tres componentes de cada horizonte deben respetar el mismo sitio o serie, las variables y unidades de entrada, la definición del evento y el umbral de decisión. Si el ensamble está configurado y alguno de sus componentes falta o resulta incompatible, el horizonte se informa como no disponible. No se redistribuyen los

pesos entre los componentes restantes ni se sustituye silenciosamente el ensamble por un modelo individual. Esta regla conserva el significado de la decisión comunicada y permite que los otros horizontes se resuelvan de manera independiente.

3.11. Empaquetado y carga de modelos

El empaquetado consiste en conservar juntos el modelo ajustado y los archivos necesarios para utilizarlo. Su propósito es evitar que una solicitud combine un modelo con variables, unidades o fechas incompatibles. Para cada componente se almacenan el modelo, el calibrador, las condiciones de uso y la información necesaria para su carga. Un archivo adicional identifica los componentes del ensamble y sus pesos para cada horizonte.

Estos archivos se recuperan desde una ubicación definida por la configuración del servicio. El usuario no selecciona libremente la ubicación de los modelos. Esta modalidad se diferencia del registro y la recuperación mediante MLflow descritos para la aplicación base. En el ensamble, la carga para realizar predicciones utiliza los archivos almacenados y no una consulta al registro de modelos de MLflow.

Antes de cargar los modelos, el servicio verifica las huellas de los archivos, la correspondencia entre sus condiciones de uso y la compatibilidad del entorno de ejecución. También comprueba el orden de las variables utilizadas por el modelo y el calibrador. Las huellas permiten detectar diferencias respecto del contenido declarado, pero no acreditan por sí solas la procedencia de los archivos. Por ello, la carga se limita a la ubicación configurada para la aplicación.

La compatibilidad temporal se examina junto con las entradas. La fecha de emisión no puede ser anterior a las fechas límite declaradas para los datos de ajuste del modelo y del calibrador. Antes de construir los retardos y las medias móviles, se seleccionan únicamente las observaciones disponibles hasta la fecha solicitada. Cuando faltan observaciones para las fechas requeridas o las entradas calculadas contienen valores no admisibles, se informa la imposibilidad de producir el pronóstico. Esta condición se distingue de una clasificación negativa.

La identificación del ensamble reúne las referencias de sus componentes, las condiciones de uso, los pesos y la versión de la regla de combinación. Cada pronóstico conserva esa identificación y las referencias individuales de los modelos. Así, una revisión posterior puede vincularse con la combinación que produjo el resultado, aunque después se disponga de otros modelos. La trazabilidad no depende únicamente del nombre de la familia de aprendizaje.

La preparación documentada para Pergamino comprendió nueve modelos y nueve calibradores, distribuidos entre tres familias y tres horizontes. Este inventario describió los componentes preparados para la demostración, sin acreditar superioridad predictiva ni validación agronómica.

3.12. Recorridos de demostración por sitio

La interfaz organiza la demostración en recorridos históricos por sitio y un laboratorio de sensores simulados. Esta separación permite reconocer el origen de las

observaciones y el propósito de cada interacción antes de interpretar un pronóstico. Los recorridos de Pergamino y Melchor Romero comparten el componente de navegación histórica, mientras que el laboratorio utiliza un entorno de simulación identificado de forma explícita. La tabla 3.6 resume sus diferencias.

TABLA 3.6. Propósito y datos de los recorridos de demostración.

Recorrido	**Origen de los datos**	**Propósito**
Pergamino	Productos externos de ERA5-Land y NASA POWER.	Consultar predicciones del ensamble preparadas sobre datos históricos y contrastarlas por horizonte.
Melchor Romero	Humedad de ESA CCI y variables climáticas de NASA POWER.	Consultar predicciones preparadas para otro sitio y contrastarlas con sus observaciones.
Laboratorio de sensores	Observaciones sintéticas, sin sensor físico conectado.	Examinar la ingesta, los controles de calidad y la interacción con el pronóstico.

El recorrido histórico del ensamble separa la generación de las predicciones de su consulta. Los modelos se aplicaron a los datos históricos y sus resultados se almacenaron antes de iniciar la navegación. Al seleccionar una fecha, el servicio recupera las predicciones correspondientes sin ejecutar nuevamente los modelos. Si no existen resultados preparados para esa fecha, informa que no están disponibles.

La fecha de emisión seleccionada identifica las predicciones que deben permanecer fijas durante la consulta. El avance del reloj determina qué observaciones pueden revelarse y cuándo pueden registrarse revisiones. Esta separación permite seguir los resultados a uno, dos y tres días de una misma emisión sin reemplazarlos por predicciones más recientes. La interfaz conserva el sitio, la fecha de emisión y la fecha simulada de la consulta para impedir que una respuesta tardía muestre información de una selección anterior.

El recorrido de Melchor Romero utiliza el mismo conjunto consolidado de observaciones que la evaluación histórica, pero con predicciones preparadas para una demostración diferente. No reproduce la ejecución experimental ni sustituye los resultados descritos en la sección 3.7. La reutilización de los datos no se interpreta, por tanto, como la reproducción del mismo experimento. Las fechas disponibles delimitan la demostración preparada y no acreditan cobertura predictiva de todo el período de la fuente.

El laboratorio permite observar situaciones controladas con datos sintéticos, identificados y separados de los recorridos históricos. Los controles de calidad y las alertas predictivas conservan significados distintos. Una lectura fuera de rango puede motivar una incidencia de calidad sin constituir, por ese hecho, una alerta de baja humedad.

3.13. Condiciones para contrastar y revisar pronósticos

La revisión de un pronóstico requiere una observación posterior que pueda utilizarse como referencia. Alcanzar la fecha objetivo es necesario, pero no suficiente. En el recorrido histórico del ensamble, el servicio comprueba primero que el reloj simulado haya alcanzado la fecha a partir de la que puede revisarse el pronóstico. Solo después consulta la humedad del suelo correspondiente a la fecha objetivo exacta. Este orden evita revelar observaciones antes del momento permitido.

Si el dato de humedad de la fecha objetivo falta, está imputado o no tiene procedencia verificada, la revisión permanece bloqueada y se informa la causa. No se utiliza una observación de un día vecino como reemplazo. El control se aplica al dato necesario para contrastar el resultado. Por ello, una variable auxiliar imputada no bloquea por sí sola la revisión.

La consulta de pronósticos y el registro de revisiones aplican las mismas condiciones. La acción habilitada en la interfaz corresponde así a la regla utilizada por el servicio al recibir la revisión. Los errores de acceso al almacenamiento se distinguen de la ausencia de observaciones. Esta separación permite reconocer si el impedimento proviene de la fecha de consulta, de la condición del dato objetivo o de un problema técnico.

La interfaz identifica los valores imputados y los de procedencia no verificada. Esta información complementa la distinción entre datos originales y derivados presentada en la sección 3.8. La indicación describe la procedencia del valor, no una clase predictiva, y permite comprender por qué un dato visible puede no ser admisible para revisar el pronóstico.

Las revisiones históricas permanecen separadas de las operativas y vinculadas con la predicción original. Su registro no actualiza los modelos ni los calibradores del ensamble.

Los mecanismos descritos permiten conservar cada predicción, identificar los modelos que la produjeron y recuperar las observaciones necesarias para interpretarla. La separación entre datos originales, valores derivados y revisiones humanas mantiene la trazabilidad del recorrido. Estas capacidades proporcionan la base técnica para examinar el funcionamiento del sistema y sus resultados, sin sustituir la evaluación del desempeño predictivo.

Capítulo 4

Ensayos y resultados

En este capítulo se presentan los ensayos realizados para evaluar la arquitectura y los principales resultados obtenidos. El análisis comprende el funcionamiento integrado, los mecanismos de robustez, el desempeño temporal de los modelos, el ensamble para distintos horizontes y la retroalimentación humana. Los resultados se interpretan distinguiendo el funcionamiento técnico del desempeño predictivo y considerando las limitaciones propias de cada estudio.

4.1. Estrategia de evaluación

Los estudios se organizaron a partir de cuatro preguntas experimentales:

- Melchor Romero. ¿Qué efecto producen los datos sintéticos, la detección de anomalías, la disponibilidad limitada de ejemplos y el ruido sobre el desempeño predictivo?
- Pergamino. ¿Cómo se comporta un modelo cuando se evalúa sobre períodos temporalmente posteriores a los utilizados para su desarrollo?
- Ensamble. ¿Qué ocurre al combinar diferentes modelos y ampliar el horizonte de predicción de uno a tres días?
- Retroalimentación. ¿Las correcciones incorporadas al entrenamiento producen cambios consistentes en el desempeño y pueden conservarse de manera trazable?

En todos los estudios, la condición positiva se definió mediante un umbral relativo de humedad del suelo. Una observación se consideró positiva cuando la humedad correspondiente a la fecha objetivo se encontraba por debajo del percentil 20 calculado exclusivamente sobre los datos de entrenamiento. Esta definición permitió establecer un criterio reproducible de baja humedad dentro de cada conjunto de datos, pero no constituyó un diagnóstico fisiológico de estrés hídrico.

El percentil utilizado para definir la condición positiva se diferenció del umbral de decisión de los clasificadores. El primero determinó qué observaciones pertenecían a la clase positiva. El segundo se fijó en 0,5 y permitió transformar la salida del modelo en una clasificación. Por lo tanto, ambos valores cumplieron funciones diferentes dentro del procedimiento experimental.

Como referencia temporal se utilizó la persistencia. Este método proyectó hacia la fecha objetivo la condición conocida en la fecha de emisión. La comparación permitió analizar si los modelos aportaban información adicional respecto de conservar el estado observado. La persistencia se utilizó como referencia predictiva y no como una regla agronómica de riego.

El coeficiente de correlación de Matthews se mantuvo como métrica principal. También se analizaron precisión, exhaustividad, F1 y, cuando correspondió, métricas asociadas con la calidad de las probabilidades. Las métricas se interpretaron de forma conjunta debido al desbalance entre las clases y a los diferentes costos potenciales de una alerta incorrecta y de una condición de baja humedad no detectada.

Los estudios realizados en Melchor Romero y Pergamino no se consideraron réplicas de un mismo experimento.

4.2. Comprobación del funcionamiento integrado

Antes de analizar el desempeño predictivo se verificó el funcionamiento conjunto de los componentes utilizados para producir y conservar pronósticos. La comprobación incluyó la carga de nueve modelos y nueve calibradores correspondientes a tres familias de clasificadores y tres horizontes de predicción.

Se utilizaron observaciones históricas de Pergamino y se recorrieron cinco fechas consecutivas de emisión, comprendidas entre el 13 y el 17 de junio de 2023. Para cada fecha se generaron predicciones a uno, dos y tres días. Se obtuvieron los quince pronósticos esperados, cuyas fechas objetivo se extendieron hasta el 20 de junio.

También se comprobó la conservación de los resultados. Cuando una solicitud se repitió con la misma identificación, se recuperó el pronóstico previamente registrado en lugar de reemplazarlo por una nueva inferencia. Al avanzar la fecha simulada de consulta, el sistema mantuvo la restricción temporal sobre las observaciones disponibles y no expuso información posterior a la fecha consultada. El recorrido permitió además registrar una revisión y verificar que esa intervención no modificara los archivos correspondientes a los modelos y calibradores.

La prueba no constituyó una medición de desempeño predictivo. Los quince pronósticos correspondieron a ausencia de alerta con acuerdo entre los tres componentes, por lo que esta comprobación tampoco cubrió todas las combinaciones posibles de acuerdo y desacuerdo.

4.3. Evaluación de los mecanismos de robustez en Melchor Romero

Esta sección evalúa la respuesta de la arquitectura frente a escenarios de escasez, ruido y calidad variable de los datos en Melchor Romero. Se comparan configuraciones con y sin generación de datos sintéticos y detección de anomalías, y se analiza la influencia de la disponibilidad temporal de las observaciones.

4.3.1. Datos y condiciones experimentales

La primera evaluación cuantitativa utilizó observaciones correspondientes a Melchor Romero durante 2024. La humedad del suelo provino de ESA CCI Soil Moisture y las variables meteorológicas se obtuvieron de NASA POWER. El horizonte de predicción se fijó en tres días y se utilizó Random Forest como predictor común para las configuraciones comparadas.

La separación entre entrenamiento y evaluación se estableció el 19 de octubre de 2024. Las predicciones evaluables tuvieron fechas de emisión comprendidas

entre el 19 de octubre y el 28 de diciembre. Las observaciones utilizadas para comprobar los resultados correspondieron al período comprendido entre el 22 de octubre y el 31 de diciembre.

Se conservaron 67 casos evaluables comunes a las ocho configuraciones analizadas. De ellos, 39 correspondieron a la clase positiva y 28 a la clase negativa. La proporción de casos positivos fue del 58,21 %. El umbral relativo de humedad fue de aproximadamente 0,316782 m^3/m^3.

La configuración base utilizó 199 ejemplos de entrenamiento. Los escenarios de disponibilidad limitada utilizaron 99 ejemplos. En un caso, los ejemplos se distribuyeron a lo largo del período de entrenamiento. En el otro, se concentraron en su tramo temporal más reciente. Esta separación permitió analizar no solo la cantidad de información disponible, sino también su distribución temporal.

Cada configuración se ejecutó con cinco semillas. Las semillas controlaron las fuentes de aleatoriedad del procedimiento sobre un mismo conjunto de evaluación y no representaron cinco sitios ni cinco muestras independientes.

La generación de datos sintéticos utilizó una distribución normal multivariada estimada a partir del entrenamiento. La detección de anomalías se incorporó mediante Isolation Forest. También se evaluó una configuración que combinó ambos mecanismos.

Los escenarios de ruido incorporaron perturbaciones gaussianas sobre las variables de entrada con una intensidad configurada de 0,3. Se evaluó un escenario con perturbación únicamente durante la evaluación y otro con perturbación durante entrenamiento y evaluación. La intensidad utilizada representó una condición experimental y no una tasa de error obtenida de sensores físicos.

4.3.2. Resultados de las configuraciones

La tabla 4.1 presenta las medias obtenidas sobre las cinco semillas. Para F1 se incluye también la desviación estándar como medida descriptiva de la variabilidad del procedimiento.

TABLA 4.1. Resultados de las configuraciones evaluadas en Melchor Romero sobre 67 casos comunes.

Configuración	F1	MCC	AP
Base	$0{,}5592 \pm 0{,}0287$	$-0{,}0135$	$0{,}5816$
Con datos sintéticos	$0{,}5450 \pm 0{,}0986$	$0{,}0582$	$0{,}6029$
Con detección de anomalías	$0{,}5689 \pm 0{,}0395$	$0{,}0110$	$0{,}5672$
Con ambos componentes	$0{,}5052 \pm 0{,}0374$	$-0{,}0706$	$0{,}5493$
Mitad del entrenamiento distribuida	$0{,}5238 \pm 0{,}0631$	$-0{,}0376$	$0{,}5913$
Mitad más reciente del entrenamiento	$0{,}6891 \pm 0{,}0407$	$0{,}1417$	$0{,}6546$
Ruido solo en evaluación	$0{,}5605 \pm 0{,}0346$	$0{,}0100$	$0{,}5755$
Ruido en entrenamiento y evaluación	$0{,}5041 \pm 0{,}0719$	$-0{,}0058$	$0{,}5804$

La configuración base obtuvo un MCC próximo a cero. La incorporación de datos sintéticos aumentó MCC y precisión promedio, pero redujo la media de F1

y produjo una dispersión mayor entre semillas. La detección de anomalías incrementó levemente F1 y MCC, mientras que la precisión promedio disminuyó. Cuando ambos mecanismos se utilizaron de manera conjunta, los valores de las tres métricas fueron inferiores a los obtenidos por la configuración base.

La figura 4.1 permite comparar visualmente el MCC obtenido por las distintas configuraciones.

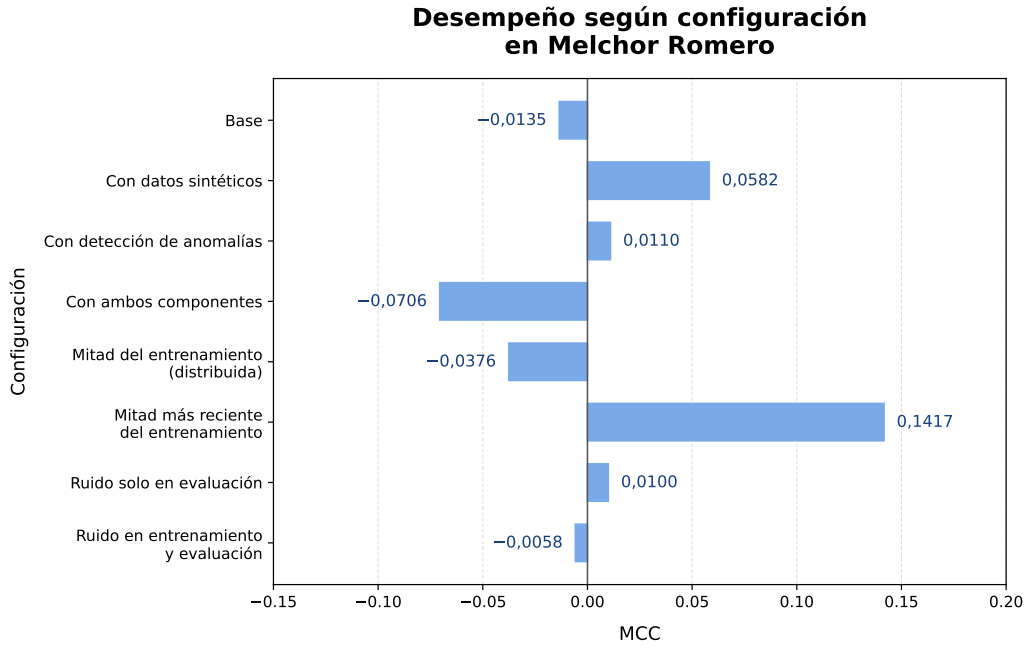


FIGURA 4.1. Coeficiente de correlación de Matthews obtenido por las configuraciones evaluadas en Melchor Romero.

El resultado más marcado apareció al modificar la distribución temporal del entrenamiento. La utilización de la mitad más reciente de los ejemplos produjo las mayores medias de F1, MCC y precisión promedio. En cambio, la selección distribuida de la misma cantidad de ejemplos no reprodujo ese comportamiento. No se interpretó este resultado como evidencia de que reducir el conjunto de entrenamiento mejore el desempeño de manera general.

La persistencia obtuvo un F1 de 0,6000 y un MCC de 0,0083. Una regla que asignó siempre la clase positiva alcanzó un F1 de 0,7358 pese a no discriminar entre casos. Este resultado mostró la necesidad de complementar F1 con métricas que consideren los cuatro componentes de la matriz de confusión. Para una clasificación constante, MCC resulta matemáticamente indeterminado. Cuando el procedimiento de evaluación utilizó el valor convencional cero para su representación, ese valor no se interpretó como una correlación estimada.

4.3.3. Disponibilidad de las observaciones

La cobertura original de humedad del suelo fue del 75,96 %. En consecuencia, aproximadamente una cuarta parte de los días no contó con una observación original de esa variable. Los valores faltantes utilizados como entradas se completaron mediante propagación causal de la última observación previa disponible. Las

observaciones empleadas para comprobar la condición objetivo no se completaron mediante ese procedimiento. Tampoco permitieron generalizar el comportamiento observado a fallas de sensores físicos ni a otros mecanismos de generación sintética.

4.4. Evaluación temporal en Pergamino

Esta sección examina el comportamiento temporal de los modelos con datos de Pergamino. Se comparan las familias de clasificadores consideradas durante el desarrollo y se evalúa la configuración seleccionada sobre períodos posteriores, junto con la interpretación de sus salidas probabilísticas.

4.4.1. Comparación de familias de modelos

La evaluación de Pergamino utilizó humedad del suelo correspondiente a la capa superficial de 0 a 7 cm de ERA5-Land y variables climáticas de NASA POWER. Se compararon regresión logística, Random Forest, HistGradientBoostingClassifier y una combinación obtenida mediante el promedio de sus probabilidades.

El desarrollo utilizó observaciones correspondientes al período 2015–2022. La comparación de familias se realizó mediante tres particiones temporales y reunió 2184 predicciones correspondientes a períodos posteriores a los utilizados para ajustar cada modelo.

La tabla 4.2 presenta el MCC obtenido por cada familia.

TABLA 4.2. Comparación de familias de modelos durante el desarrollo con datos de Pergamino.

Familia	**MCC**
Combinación por promedio	0,7080
Regresión logística	0,6980
Random Forest	0,6954
HistGradientBoostingClassifier	0,6858

La combinación por promedio obtuvo el mayor valor puntual de MCC. Sin embargo, las diferencias entre las familias no proporcionaron evidencia suficiente para establecer una superioridad estable. El procedimiento había definido previamente un margen práctico de 0,05 para distinguir candidatos. Al no observarse una diferencia estable que justificara seleccionar una familia por desempeño superior, se aplicó el criterio de desempate previamente establecido y se seleccionó la regresión logística por su menor complejidad.

Los análisis posteriores de esta sección corresponden, por lo tanto, a la regresión logística y no al ensamble presentado posteriormente.

4.4.2. Evaluación sobre períodos posteriores

La configuración seleccionada se evaluó sobre dos períodos posteriores. Para 2023 se ajustó el modelo con información disponible hasta 2022. Para la evaluación correspondiente a 2024–2025 se incorporaron al entrenamiento los datos disponibles hasta 2023, sin modificar la familia de modelo seleccionada.

El umbral relativo de humedad se calculó nuevamente sobre el conjunto de entrenamiento correspondiente a cada etapa. Por esta razón, las métricas de ambos períodos describieron el comportamiento del procedimiento en cada condición temporal y no se interpretaron como una comparación directa entre dos modelos idénticos entrenados sobre la misma información.

La evaluación de 2023 comprendió 362 casos, de los cuales 96 correspondieron a la clase positiva. La evaluación de 2024–2025 incluyó 728 casos, con 128 positivos. Las proporciones de casos positivos fueron del 26,52 % y del 17,58 %, respectivamente.

La tabla 4.3 compara el modelo con la persistencia dentro de cada período.

TABLA 4.3. Resultados de la regresión logística y de la persistencia a tres días en Pergamino.

Período	Método	MCC	F1	Precisión	Exhaustividad
2023	Regresión logística	0,7014	0,7792	0,6667	0,9375
2023	Persistencia	0,6147	0,7158	0,7234	0,7083
2024–2025	Regresión logística	0,6648	0,7192	0,6032	0,8906
2024–2025	Persistencia	0,5734	0,6484	0,6484	0,6484

En 2023, el modelo identificó 90 de los 96 casos positivos y omitió 6. También produjo 45 falsas alertas. La persistencia identificó 68 casos positivos, omitió 28 y produjo 26 falsas alertas. En consecuencia, el incremento de la exhaustividad estuvo acompañado por una reducción de la precisión y una mayor cantidad de falsas alertas.

En 2024–2025 se observó un comportamiento semejante. El modelo identificó 114 de los 128 casos positivos y omitió 14, con 75 falsas alertas. La persistencia identificó 83 casos positivos, omitió 45 y produjo 45 falsas alertas. Estos resultados mostraron un intercambio entre capacidad de detección y cantidad de alertas incorrectas. La evaluación no asignó un costo agronómico a ambos tipos de error, por lo que las métricas no permitieron determinar por sí solas qué relación resultaría preferible en una aplicación productiva.

Para considerar la dependencia temporal de las observaciones, la diferencia de MCC respecto de la persistencia se analizó mediante remuestreo pareado por bloques de 30 días. Se utilizaron 5000 remuestreos y, en cada uno, ambos métodos fueron evaluados sobre los mismos días.

En 2023, la diferencia de MCC fue de 0,0866 y el intervalo del 95 % se extendió aproximadamente entre $-0{,}0146$ y $0{,}2092$. Debido a que el intervalo incluyó el cero, el resultado no estableció una diferencia concluyente entre ambos métodos. El límite inferior, sin embargo, se mantuvo por encima del margen de no inferioridad de $-0{,}05$ definido para el estudio.

En 2024–2025, la diferencia de MCC fue de 0,0913 y el intervalo del 95 % se extendió entre $0{,}0227$ y $0{,}1784$. En este caso, el intervalo no incluyó el cero. El resultado constituyó evidencia favorable para la regresión logística frente a la persistencia dentro de esa serie y ese período.

La interpretación de estos resultados se mantuvo como retrospectiva y exploratoria. Determinados controles metodológicos previstos para autorizar las etapas posteriores quedaron formalizados después de las ejecuciones correspondientes. Esta desviación no modificó los valores obtenidos, pero impidió presentar los resultados como una validación confirmatoria independiente. Tampoco permitió

extrapolarlos a otros sitios, cultivos o condiciones productivas.

4.4.3. Interpretación de las probabilidades

Un buen desempeño de clasificación no implica que las probabilidades estimadas puedan interpretarse directamente como frecuencias esperadas. Esta diferencia se examinó sobre el período 2024–2025.

Entre las predicciones comprendidas entre 0,9 y 1,0 se identificaron 83 casos. La probabilidad media del grupo fue de 0,9643, mientras que la proporción de casos positivos observados fue de 0,6627. La diferencia indicó una sobreestimación de la probabilidad en ese intervalo.

Al mismo tiempo, el modelo obtuvo un área bajo la curva ROC de 0,9390 y una puntuación de Brier de 0,0975. Estos resultados muestran que la capacidad para ordenar observaciones y la correspondencia entre probabilidades y frecuencias observadas representan propiedades diferentes del predictor.

4.5. Evaluación del ensamble y del horizonte de anticipación

Esta sección analiza el desempeño de los modelos y de sus combinaciones para horizontes de uno, dos y tres días. Se consideran el desempeño predictivo, las falsas alertas y omisiones, la anticipación de condiciones de baja humedad y la calibración de las salidas.

4.5.1. Preparación del estudio

El análisis del ensamble examinó el comportamiento de tres familias de clasificadores: regresión logística, Random Forest e HistGradientBoostingClassifier. Para cada familia se dispuso de un modelo específico para horizontes de uno, dos y tres días. Los modelos se ajustaron con observaciones correspondientes al período 2015–2021 y sus calibradores se prepararon con datos de 2022. La evaluación retrospectiva utilizó observaciones de Pergamino correspondientes a 2023.

El umbral relativo de humedad fue de aproximadamente 0,313058 m^3/m^3. La salida del ensamble se calculó mediante el promedio de las tres salidas calibradas con pesos iguales. Una probabilidad media igual o superior a 0,5 produjo una clasificación positiva.

Este estudio utilizó una preparación diferente de la evaluación temporal presentada en la sección anterior. Por lo tanto, sus resultados no se combinaron ni se interpretaron como una repetición del mismo experimento. Además, el período 2023 ya había intervenido en análisis previos del proyecto. En consecuencia, esta evaluación se consideró retrospectiva y exploratoria, no una validación independiente.

Se dispuso de 364 casos comunes para el horizonte de un día, 363 para dos días y 362 para tres días. En los tres horizontes se registraron 112 casos positivos. La reducción del número total de casos al ampliar el horizonte se debió a que la observación objetivo debía permanecer dentro del período evaluado.

4.5.2. Desempeño según el horizonte

La tabla 4.4 presenta el MCC obtenido por los tres modelos, el promedio de sus probabilidades, la persistencia y una regla de mayoría. Esta última emitió una alerta cuando al menos dos de los tres modelos individuales produjeron una clasificación positiva.

TABLA 4.4. MCC de los modelos y sus combinaciones en Pergamino durante 2023.

Método	1 día	2 días	3 días
Regresión logística	0,8287	0,7941	0,7079
Random Forest	0,8376	0,7278	0,6514
HistGradientBoostingClassifier	0,8560	0,7310	0,6155
Ensamble por promedio	0,8376	0,7566	0,6804
Persistencia	0,8255	0,7146	0,6159
Mayoría de votos	0,8447	0,7520	0,6634

El MCC disminuyó al ampliar el horizonte en todos los métodos evaluados.

El ensamble por promedio presentó valores puntuales de MCC superiores a la persistencia en los tres horizontes, pero no alcanzó el mayor MCC en ninguno de ellos. A un día, HistGradientBoostingClassifier obtuvo el valor más elevado. A dos y tres días, el mayor valor correspondió a la regresión logística. Por lo tanto, la combinación de modelos no produjo una superioridad sistemática respecto de sus componentes individuales.

La figura 4.2 resume esta evolución para el ensamble por promedio, la regresión logística y la persistencia.

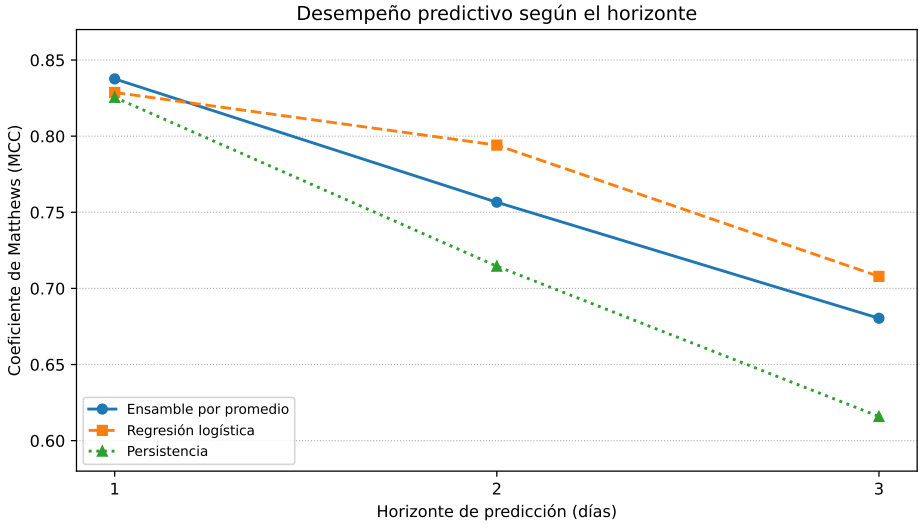


FIGURA 4.2. Evolución del coeficiente de correlación de Matthews según el horizonte de predicción para el ensamble por promedio, la regresión logística y la persistencia.

4.5.3. Falsas alertas y omisiones

La tabla 4.5 complementa el MCC con las falsas alertas y omisiones del ensamble por promedio, la mayoría de votos y la persistencia.

TABLA 4.5. Falsas alertas y omisiones según el horizonte de predicción.

Horizonte	Método	Falsas alertas	Omisiones
1 día	Ensamble por promedio	22	5
1 día	Mayoría de votos	22	4
1 día	Persistencia	13	14
2 días	Ensamble por promedio	40	4
2 días	Mayoría de votos	41	4
2 días	Persistencia	21	23
3 días	Ensamble por promedio	52	7
3 días	Mayoría de votos	58	6
3 días	Persistencia	28	31

Al ampliar el horizonte, la persistencia produjo menos falsas alertas que las combinaciones de modelos, pero también una cantidad mayor de omisiones. A tres días, el ensamble por promedio omitió 7 casos positivos frente a 31 de la persistencia. Como contrapartida, produjo 52 falsas alertas frente a 28.

Este resultado mostró un intercambio entre sensibilidad y falsas alarmas. El experimento no incorporó una valoración agronómica o económica de ambos tipos de error. Por esta razón, no se estableció qué relación entre omisiones y falsas alertas resultaría preferible para una decisión real de riego.

Los intervalos del 95 % para la diferencia de MCC entre el ensamble por promedio y la persistencia fueron aproximadamente $[-0{,}0322; 0{,}0652]$ a un día, $[-0{,}0221; 0{,}1197]$ a dos días y $[-0{,}0423; 0{,}1541]$ a tres días. Los tres intervalos incluyeron el cero.

La regresión logística presentó diferencias favorables frente a la persistencia a dos y tres días. Los intervalos correspondientes fueron aproximadamente $[0{,}0269; 0{,}1662]$ y $[0{,}0096; 0{,}1945]$. Estos contrastes utilizaron 5000 remuestreos pareados de bloques de 30 días y se interpretaron como resultados exploratorios.

4.5.4. Anticipación de transiciones hacia baja humedad

Además de la clasificación diaria, se examinó la capacidad retrospectiva para identificar situaciones en las que la condición de baja humedad todavía no se encontraba presente en la fecha de emisión, pero aparecía en la fecha objetivo. Este análisis permitió estudiar de manera más directa el concepto de anticipación utilizado en el trabajo.

Se identificaron 14 casos de este tipo a un día, 23 a dos días y 31 a tres días. La tabla 4.6 muestra cuántos fueron identificados por cada método.

La persistencia no identificó ninguna de estas transiciones porque su definición conserva hacia el futuro la condición observada en la fecha de emisión. Los modelos predictivos, en cambio, identificaron una parte de los casos en los que la humedad descendió posteriormente por debajo del umbral.

La figura 4.3 muestra la proporción de transiciones identificadas por cada método para los tres horizontes.

TABLA 4.6. Identificación de transiciones hacia la condición de baja humedad.

Método	1 día	2 días	3 días
HistGradientBoostingClassifier	13/14	18/23	26/31
Regresión logística	8/14	17/23	20/31
Random Forest	9/14	18/23	27/31
Ensamble por promedio	9/14	19/23	24/31
Persistencia	0/14	0/23	0/31
Mayoría de votos	10/14	19/23	26/31

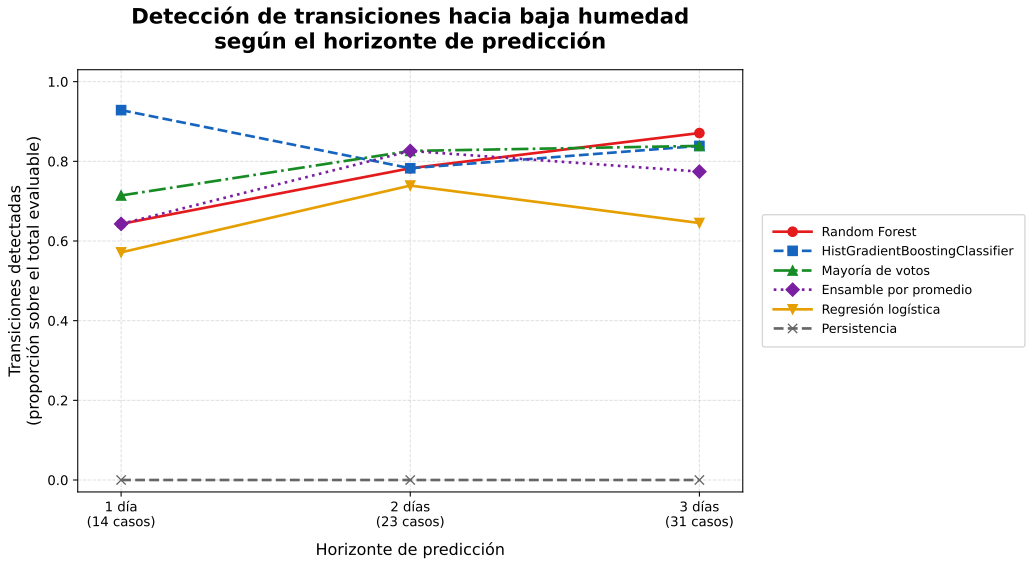


FIGURA 4.3. Proporción de transiciones hacia la condición de baja humedad identificadas por cada método según el horizonte de predicción.

Este resultado proporcionó evidencia de anticipación retrospectiva dentro del conjunto evaluado. No se interpretó como anticipación agronómica en campo ni como demostración de utilidad operativa, debido a que las predicciones se analizaron sobre datos históricos y la condición objetivo se definió mediante un umbral relativo de humedad.

4.5.5. Anticipación de episodios de baja humedad

El análisis de las transiciones individuales se complementó con una evaluación de episodios. Un episodio representó una secuencia temporal asociada con la condición de baja humedad definida para el estudio. Esta perspectiva permitió evitar que varios días consecutivos pertenecientes a una misma situación fueran interpretados exclusivamente como eventos independientes.

Durante 2023 se identificaron 14 episodios evaluables. La tabla 4.7 presenta la cantidad de episodios detectados por cada método para los tres horizontes analizados.

TABLA 4.7. Episodios de baja humedad identificados según el horizonte de predicción.

Método	1 día	2 días	3 días
HistGradientBoostingClassifier	13/14	10/14	11/14
Regresión logística	8/14	8/14	6/14
Random Forest	9/14	10/14	11/14
Ensamble por promedio	9/14	10/14	9/14
Persistencia	0/14	3/14	3/14
Mayoría de votos	10/14	10/14	11/14

La comparación por episodios complementó las métricas calculadas sobre observaciones diarias. Una clasificación incorrecta en una fecha determinada no implicó necesariamente la omisión completa de un episodio, del mismo modo que la detección de algún día perteneciente a un episodio no significó que todas sus observaciones hubieran sido correctamente clasificadas.

La cantidad limitada de episodios exigió una interpretación prudente. Los resultados permitieron caracterizar el comportamiento retrospectivo de los modelos sobre el período analizado, pero no establecer una tasa general de detección de episodios aplicable a otras campañas, sitios o cultivos.

4.5.6. Calibración de las salidas del ensamble

La existencia de calibradores no garantizó por sí sola una correspondencia adecuada entre las salidas numéricas y las frecuencias observadas.

La figura 4.4 presenta la relación entre la salida media del modelo y la proporción de casos positivos observada en cada intervalo.

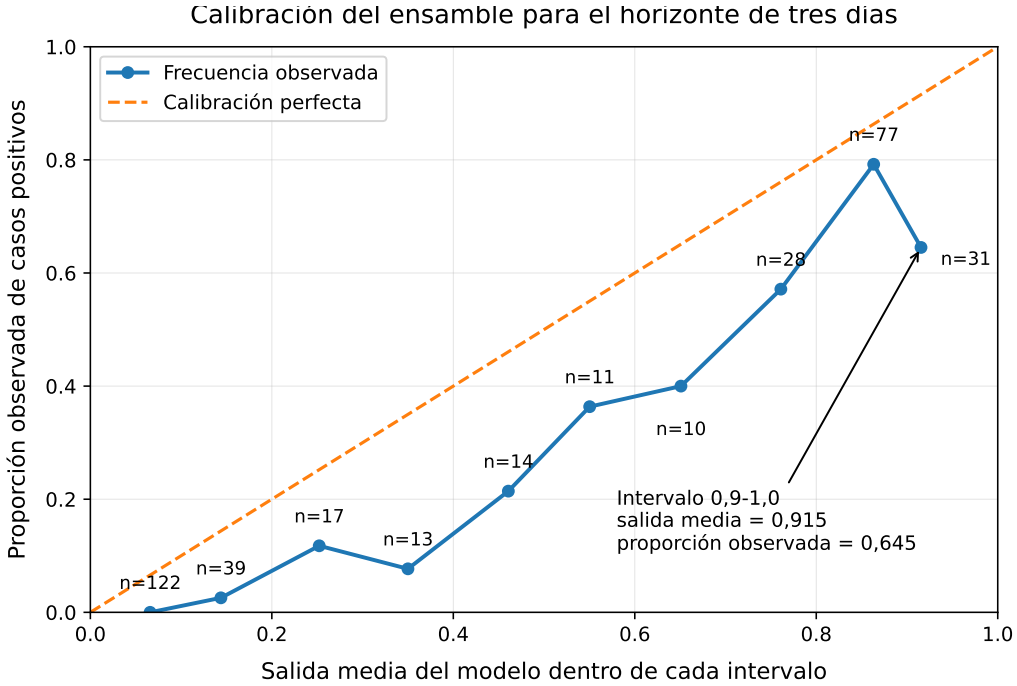


FIGURA 4.4. Relación entre la salida media del ensamble y la proporción observada de casos positivos para el horizonte de tres días.

La diagonal representa una correspondencia ideal entre ambas magnitudes. La separación respecto de esa referencia permite observar que una salida numérica elevada no implicó necesariamente una frecuencia observada equivalente.

A tres días, 31 predicciones del ensamble por promedio se encontraron dentro del intervalo comprendido entre 0,9 y 1,0. La media de sus salidas fue aproximadamente 0,915, mientras que la proporción positiva observada dentro de ese grupo fue aproximadamente 0,645.

Esta diferencia indicó que las salidas de alta magnitud sobreestimaron la frecuencia observada de la condición positiva dentro de ese intervalo. En consecuencia, los valores producidos por el ensamble no se interpretaron como porcentajes de riesgo validados.

4.6. Evaluación de la retroalimentación y la recalibración

La última parte de la evaluación examinó el funcionamiento de la retroalimentación humana en dos dimensiones: la posibilidad técnica de registrar y utilizar correcciones y el efecto que esas correcciones pudieran producir sobre el desempeño predictivo.

4.6.1. Efecto de correcciones simuladas

La evaluación controlada comparó tres condiciones. La primera correspondió a un modelo que no incorporó información adicional. La segunda reajustó el modelo con nuevos datos, pero sin aplicar correcciones sobre las etiquetas. La tercera utilizó los mismos datos adicionales e incorporó las correcciones correspondientes.

Esta separación permitió distinguir el efecto de disponer de un período adicional de entrenamiento del efecto específico de modificar las etiquetas. Sin esta comparación, cualquier cambio posterior a la actualización podría haberse atribuido incorrectamente a la retroalimentación.

El estudio utilizó datos de Pergamino. Las correcciones correspondieron a eventos de 2021 y la evaluación se realizó sobre 362 casos de 2022. Los eventos utilizados para las correcciones no coincidieron con los casos empleados para evaluar los modelos.

Se introdujo de manera controlada una proporción de corrupción de etiquetas de 0,10. Para cada semilla se seleccionaron veinte eventos, distribuidos entre diez casos clasificados como alerta y diez casos clasificados como ausencia de alerta. El procedimiento se repitió con cinco semillas.

La tabla 4.8 presenta el MCC obtenido en cada condición. La última columna muestra la diferencia entre el modelo actualizado con correcciones y el modelo actualizado con los mismos datos, pero sin aplicar esas correcciones.

Las diferencias tuvieron signos distintos. Tres fueron positivas y dos negativas. Por lo tanto, la incorporación de las correcciones no produjo una mejora uniforme del MCC.

No se calcularon intervalos de incertidumbre para este contraste. Las diferencias se interpretaron de manera descriptiva y las cinco semillas se consideraron repeticiones del procedimiento bajo diferentes fuentes de aleatoriedad, no poblaciones independientes.

TABLA 4.8. MCC por semilla en la evaluación de correcciones simuladas.

Semilla	Sin actualizar	Sin correcciones	Con correcciones	Diferencia
0	0,453707	0,510678	0,476741	-0,0339
1	0,475442	0,431719	0,440070	0,0084
2	0,479627	0,482246	0,489338	0,0071
3	0,446347	0,502817	0,507204	0,0044
4	0,464042	0,469509	0,468237	-0,0013

4.6.2. Prueba de interacción humana

El funcionamiento del circuito de revisión también se examinó mediante una interacción humana controlada. Un único operador revisó veinte registros y aceptó los veinte casos presentados. Como consecuencia, no se introdujeron correcciones y no se inició una actualización del modelo a partir de esa revisión.

Dentro de los veinte registros se habían incorporado cuatro etiquetas invertidas de manera controlada. El operador no identificó ninguna de ellas. El procedimiento simulado, que disponía de la regla utilizada como referencia, corrigió los cuatro casos.

Esta prueba permitió comprobar que una revisión podía registrarse y conservarse junto con la predicción correspondiente. No demostró capacidad humana para detectar errores ni una mejora predictiva derivada de la intervención.

La interpretación estuvo además limitada por las condiciones de la prueba. Participó un único operador vinculado con el desarrollo del sistema y no intervinieron especialistas agronómicos ni productores. La observación posterior y el umbral utilizado para definir la condición también estuvieron disponibles durante la revisión.

4.7. Discusión de los resultados

Los resultados muestran que la contribución de los componentes dependió del conjunto de datos, la distribución temporal de las observaciones, el horizonte y el mecanismo evaluado.

En Pergamino, la regresión logística fue seleccionada durante el desarrollo por un criterio predefinido de simplicidad y mostró mayor exhaustividad que la persistencia en los períodos posteriores, a costa de más falsas alertas. En 2024–2025, el intervalo de la diferencia de MCC frente a persistencia no incluyó el cero, lo que constituye evidencia favorable dentro de esa serie y período. La interpretación continuó siendo retrospectiva y exploratoria.

El aumento del horizonte redujo el MCC en todos los métodos analizados. El ensamble por promedio no presentó una superioridad sistemática frente a sus componentes ni una diferencia concluyente frente a persistencia en los intervalos pareados. Sin embargo, a tres días redujo de forma importante las omisiones respecto de la persistencia, aunque incrementó las falsas alertas. Las transiciones y episodios de baja humedad mostraron capacidad retrospectiva de anticipación en los modelos predictivos, pero no acreditaron utilidad agronómica ni operativa.

Las salidas de alta magnitud sobreestimaron la frecuencia observada en determinados intervalos, por lo que no se interpretaron como probabilidades de riesgo.

4.8. Alcance de la evidencia respecto de la hipótesis

La hipótesis planteó que la combinación de generación de datos sintéticos, detección de anomalías, modelado predictivo y retroalimentación humana podía mejorar la detección temprana bajo condiciones de escasez, ruido y variabilidad de datos. La evidencia obtenida no permitió sostener una mejora general atribuible a la combinación de los cuatro componentes.

La retroalimentación humana quedó implementada de forma funcional y trazable, pero las correcciones simuladas no produjeron una mejora uniforme y la interacción humana no aportó evidencia de beneficio predictivo. En consecuencia, la hipótesis no quedó respaldada en su formulación general. Los experimentos sí permitieron identificar contribuciones específicas, condiciones favorables y limitaciones que orientan evaluaciones posteriores.

4.9. Limitaciones de la evaluación

Los resultados deben interpretarse dentro de las condiciones de los estudios realizados. Las fuentes utilizadas correspondieron a productos satelitales, meteorológicos y de reanálisis. No se utilizaron mediciones obtenidas mediante una instalación propia de sensores en una explotación hortícola.

La condición objetivo se definió mediante un umbral relativo de humedad del suelo. Por lo tanto, los resultados describieron la anticipación de una condición de baja humedad dentro de cada conjunto de datos y no un diagnóstico fisiológico validado de estrés hídrico.

La evaluación de Melchor Romero estuvo condicionada por la disponibilidad de las observaciones originales de humedad. Aproximadamente una cuarta parte de los días requirió completar las entradas mediante propagación causal. No se realizó un experimento equivalente sobre una serie completa que permitiera aislar el efecto de esa reconstrucción.

Los escenarios de ruido utilizaron una perturbación experimental que no fue calibrada contra una caracterización física del error de un sensor. En consecuencia, permitieron estudiar la respuesta del procedimiento ante una perturbación controlada, pero no estimar su comportamiento frente a un nivel real de ruido instrumental.

Los estudios de Pergamino utilizaron períodos históricos y no constituyeron una evaluación prospectiva en campo. Tampoco se midió la latencia real entre la ocurrencia de una observación y su disponibilidad para producir una alerta.

Las diferencias entre sitios, períodos, fuentes y umbrales impidieron interpretar Melchor Romero y Pergamino como una comparación geográfica directa. Los resultados de un sitio no se utilizaron para afirmar generalización hacia el otro.

El análisis del ensamble correspondiente a 2023 tuvo carácter retrospectivo y exploratorio. Ese período ya había intervenido en análisis previos del proyecto. Los resultados permitieron estudiar el comportamiento de los modelos y del ensamble, pero no constituyeron una evaluación independiente.

La evaluación de retroalimentación utilizó correcciones simuladas y una interacción humana de alcance limitado. No participaron especialistas agronómicos ni productores y no se realizó una evaluación de uso en condiciones productivas.

Finalmente, no se evaluaron ahorro de agua, rendimiento del cultivo, decisiones reales de riego ni beneficios agronómicos. Estas variables quedaron fuera del alcance experimental del trabajo. En consecuencia, los resultados obtenidos no permiten establecer conclusiones sobre la eficacia agronómica de la arquitectura ni sobre su impacto en el uso del recurso hídrico.

Capítulo 5

Conclusiones

Este capítulo sintetiza los aportes y las limitaciones de la arquitectura evaluada y propone líneas de trabajo futuro.

5.1. Conclusiones generales

Se diseñó e implementó una arquitectura de inteligencia artificial orientada a anticipar condiciones de baja humedad del suelo bajo escenarios de escasez, ruido y variabilidad de datos. La implementación involucró la preparación de observaciones, la generación de datos sintéticos, la detección de anomalías, el modelado predictivo y la retroalimentación humana. Los ensayos con datos de Melchor Romero y Pergamino permitieron examinar su funcionamiento y el aporte de los mecanismos evaluados.

La integración permitió conservar pronósticos, identificar los modelos utilizados y vincular las revisiones con sus registros de origen. La reproducción histórica mantuvo las predicciones fijas y reveló las observaciones posteriores según una fecha simulada. Estas capacidades aportaron trazabilidad y constituyeron evidencia de factibilidad técnica dentro del alcance del prototipo.

En Melchor Romero, la generación sintética y la detección de anomalías no aportaron mejoras uniformes y su combinación no superó a la configuración base. Una selección reciente de observaciones obtuvo un comportamiento más favorable que una selección distribuida de igual tamaño. Estos resultados mostraron la relevancia de la distribución temporal de los datos y la necesidad de evaluar cada mecanismo en condiciones específicas.

En Pergamino se observó capacidad retrospectiva para anticipar baja humedad. Frente a persistencia, los modelos detectaron más casos positivos y algunas transiciones futuras, aunque produjeron más falsas alertas. El ensamble no superó sistemáticamente a sus componentes. Las salidas de alta magnitud sobreestimaron la frecuencia observada en determinados intervalos, lo que limitó su interpretación como probabilidades de riesgo.

La retroalimentación permitió registrar revisiones y actualizaciones trazables, pero las correcciones simuladas no produjeron una mejora uniforme y la prueba de interacción humana no aportó evidencia de beneficio predictivo. Las revisiones de los recorridos históricos del ensamble tuvieron fines demostrativos y no modificaron sus modelos. No se implementó aprendizaje continuo autónomo.

La evidencia no respaldó la hipótesis en su formulación general: no se demostró una mejora atribuible a la combinación de todos los componentes. El trabajo permitió materializar la propuesta, contrastar sus mecanismos e identificar aportes y limitaciones. La factibilidad técnica y la mejora predictiva constituyeron dimensiones diferentes de la evaluación.

Las conclusiones se limitaron a los datos y períodos estudiados. El objetivo fue un indicador relativo de baja humedad, sin validación fisiológica del cultivo. La evaluación retrospectiva y las limitaciones descritas en el capítulo 4 impidieron afirmar generalización geográfica, ahorro de agua, mejora del rendimiento o beneficios de decisiones reales de riego.

5.2. Trabajo futuro

La prioridad consiste en evaluar la arquitectura con una campaña independiente y un protocolo fijado antes de examinar los resultados. La comparación debería separar ajuste y evaluación, considerar la dependencia temporal y mantener condiciones comunes para estimar el aporte individual y conjunto de los componentes.

Será necesario incorporar referencias agronómicas independientes y participación de especialistas para relacionar las alertas con el estado del cultivo, definir la anticipación útil y valorar falsas alertas y omisiones. La calibración de probabilidades y la selección de umbrales deberían verificarse con datos separados de los utilizados para ajustar los modelos.

La evaluación de robustez debería incorporar registros de disponibilidad real y errores de medición para distinguir el efecto del predictor del asociado con la reconstrucción de entradas faltantes. Nuevos períodos y sitios permitirían comparar el ajuste específico para cada fuente con la transferencia de modelos entrenados.

El estudio de la retroalimentación debería incluir participantes ajenos al desarrollo y comparar actualizaciones con nuevos datos frente a actualizaciones con esos mismos datos y correcciones humanas. Una futura actualización continua requeriría controles de calidad, evaluación temporal y criterios para aceptar o revertir cambios.

Finalmente, una prueba prospectiva permitiría medir la demora de disponibilidad de los datos, la estabilidad del servicio y el uso efectivo de las alertas. Los posibles beneficios sobre el riego y el cultivo exigirían una evaluación agronómica específica.

Bibliografía

[1] Cho et al. «Recent Methods for Evaluating Crop Water Stress Using AI Techniques: A Review». En: *Sensors* 24.19 (2024), pág. 6313. URL: https://www.mdpi.com/1424-8220/24/19/6313.

[2] «Advances in machine learning for agricultural water management». En: *Journal of Hydroinformatics* 27.3 (2024), pág. 474. URL: https://iwaponline.com/jh/article/27/3/474/107443/Advances-in-machine-learning-for-agricultural-water-management.

[3] «Crop water stress detection based on UAV remote sensing». En: *ScienceDirect* (2024). URL: https://www.sciencedirect.com/.

[4] Zhengwei et al. *A Machine Learning-Based High-Resolution Soil Moisture Mapping Method*. Inf. téc. USDA National Agricultural Statistics Service (NASS), 2024. URL: https://www.nass.usda.gov/Research_and_Science/Cropland/docs/Zhengwei_2024_High-Resolution_Soil_Moisture_Mapping.pdf.

[5] «Human-in-the-Loop Artificial Intelligence: A Systematic Review of Concepts, Methods, and Applications». En: *Entropy* 28.4 (2026), pág. 377. URL: https://www.mdpi.com/1099-4300/28/4/377.

[6] *HILAD: A Reliable Framework for Human-in-the-Loop Anomaly Detection in Time Series*. arXiv preprint. 2024.

[7] «Estimación del estrés hídrico en cultivos extensivos en la región pampeana mediante imágenes de temperatura de superficie e índices de vegetación». En: *SciELO Argentina* (2013). URL: https://www.scielo.org.ar/scielo.php?script=sci_arttext\&pid=S1852-42652013000200005.

[8] «DeepQC: A deep learning system for automatic quality control of soil moisture sensor time series data». En: *ScienceDirect* (2024). URL: https://www.sciencedirect.com/science/article/pii/S2772375524001199.

[9] *Self-Supervised Anomaly Detection of Rogue Soil Moisture Sensors*. arXiv preprint. 2023.

[10] «A review of synthetic data generation in smart farming by using VAE and GAN». En: *Engineering Applications of Artificial Intelligence* (2024). URL: https://www.sciencedirect.com/science/article/abs/pii/S0952197624000393.

[11] S. Basnayake et al. «Human-In-The-Loop AI for Precision Agriculture: A Scoping Review». En: *International Journal of Latest Technology in Engineering, Management & Applied Science* (2026). URL: https://www.ijltemas.in/submission/online/article/view/4152.

[12] «Efecto del estrés salino en el régimen hídrico, compuestos osmóticamente activos y pigmentos fotosintéticos en cultivares de tomate». En: *SciELO Argentina* (2023). URL: https://www.scielo.org.ar/scielo.php?script=sci_arttext\&pid=S1669-23142023000100032.

[13] Instituto Nacional de Tecnología Agropecuaria (INTA). *Sensor de Humedad de Suelo B01*. Sitio web institucional del INTA. Documentación técnica de instrumento. URL: https://www.argentina.gob.ar/inta/tecnologias/sensor-humedad-de-suelo-b01.

[14] Pete Chapman et al. *CRISP-DM 1.0: Step-by-step Data Mining Guide*. Inf. téc. SPSS, 2000.

[15] Alexander Gruber et al. «Evolution of the ESA CCI Soil Moisture climate data records and their underlying merging methodology». En: *Earth System Science Data* 11 (2019), págs. 717-739. DOI: 10.5194/essd-11-717-2019.

[16] Wouter Dorigo et al. «ESA CCI Soil Moisture for improved Earth system understanding: State-of-the art and future directions». En: *Remote Sensing of Environment* (2017). DOI: 10.1016/j.rse.2017.07.001.

[17] Wolfgang Preimesberger et al. «Homogenization of Structural Breaks in the Global ESA CCI Soil Moisture Multisatellite Climate Data Record». En: *IEEE Transactions on Geoscience and Remote Sensing* 59.4 (2021), págs. 2845-2862. DOI: 10.1109/TGRS.2020.3012896.

[18] NASA POWER Project. *NASA POWER Documentation*. URL: https://power.larc.nasa.gov/docs/ (visitado 17-09-2026).

[19] Fei Tony Liu, Kai Ming Ting y Zhi-Hua Zhou. «Isolation Forest». En: *Proceedings of the 2008 Eighth IEEE International Conference on Data Mining*. 2008, págs. 413-422. DOI: 10.1109/ICDM.2008.17.

[20] Leo Breiman. «Random Forests». En: *Machine Learning* 45 (2001), págs. 5-32. DOI: 10.1023/A:1010933404324.

[21] scikit-learn developers. *Linear Models: Logistic regression*. URL: https://scikit-learn.org/stable/modules/linear_model.html#logistic-regression (visitado 17-09-2026).

[22] Jerome H. Friedman. «Greedy Function Approximation: A Gradient Boosting Machine». En: *The Annals of Statistics* 29.5 (2001), págs. 1189-1232. DOI: 10.1214/aos/1013203451.

[23] scikit-learn developers. *Ensembles: Gradient boosting, random forests, bagging, voting, stacking*. URL: https://scikit-learn.org/stable/modules/ensemble.html (visitado 17-09-2026).

[24] Brian W. Matthews. «Comparison of the Predicted and Observed Secondary Structure of T4 Phage Lysozyme». En: *Biochimica et Biophysica Acta – Protein Structure* 405.2 (1975), págs. 442-451. DOI: 10.1016/0005-2795(75)90109-9.

[25] scikit-learn developers. *Metrics and scoring: quantifying the quality of predictions*. URL: https://scikit-learn.org/stable/modules/model_evaluation.html (visitado 17-09-2026).

[26] Glenn W. Brier. «Verification of Forecasts Expressed in Terms of Probability». En: *Monthly Weather Review* 78.1 (1950), págs. 1-3. DOI: 10.1175/1520-0493(1950)078<0001:VOFEIT>2.0.CO;2.

[27] Hans R. Künsch. «The Jackknife and the Bootstrap for General Stationary Observations». En: *The Annals of Statistics* 17.3 (1989), págs. 1217-1241. DOI: 10.1214/aos/1176347265.

[28] S. N. Lahiri. *Resampling Methods for Dependent Data*. Springer Series in Statistics. Springer, 2003. DOI: 10.1007/978-1-4757-3803-2.