



Arquitectura de inteligencia artificial para detección temprana de estrés hídrico en cultivos hortícolas bajo escenarios de escasez y variabilidad de datos

Autor:

Esp. Lic. Gustavo Julián Rivas

Director:

PhD. Ms. Camilo Enrique Argoty Pulido (FIUBA)

*Esta planificación fue realizada en el curso de gestión de proyectos
entre el 23 de junio de 2026 y el 18 agosto de 2026.*

Índice

1. Descripción técnica-conceptual del proyecto a realizar	5
2. Identificación y análisis de los interesados	7
3. Propósito del proyecto	7
4. Alcance del proyecto	8
5. Supuestos del proyecto.	9
6. Product Backlog	9
7. Criterios de aceptación de historias de usuario	11
8. Fases de CRISP-DM	13
9. Desglose del trabajo en tareas	16
10. Planificación de Sprints	18
11. Diagrama de Gantt (sprints)	22
12. Gobernanza de datos	28
12.1 Cumplimiento normativo	28
12.2 Ética en el uso de inteligencia artificial	28
13. Gestión de riesgos	29
13.1 Identificación de los riesgos y estimación de sus consecuencias	29
13.2 Tabla de gestión de riesgos	32
13.3 Plan de mitigación	32
14. Sprint Review	33
15. Sprint Retrospective	35

Registros de cambios

Revisión	Detalles de los cambios realizados	Fecha
0	Creación del documento	23 de junio de 2026
1	Se completa hasta el punto 5 inclusive	4 de julio de 2026
2	Se realizan correcciones de la primera entrega. Se completa desde el punto 6 hasta el punto 9 inclusive.	11 de julio de 2026
2.1	Se realizan correcciones de la versión 2	14 de julio de 2026
3	Se realizan correcciones de la versión 2.1. Se completa hasta el punto 12 inclusive	19 de julio de 2026
4	Se realizan correcciones de la versión 3. Se completa hasta el punto 15 inclusive	26 de julio de 2026
4.1	Se realizan correcciones de la versión 4.	1 de agosto de 2026

Acta de constitución del proyecto

Buenos Aires, 23 de junio de 2026

Por medio de la presente se acuerda con el Esp. Lic. Gustavo Julián Rivas que su Trabajo Final de la Maestría en Inteligencia Artificial de la Facultad de Ingeniería de la Universidad de Buenos Aires se titulará “Arquitectura de inteligencia artificial para detección temprana de estrés hídrico en cultivos hortícolas bajo escenarios de escasez y variabilidad de datos” y consistirá en investigar, diseñar y evaluar una arquitectura basada en técnicas de inteligencia artificial orientada a mejorar la detección temprana de condiciones de estrés hídrico en cultivos hortícolas, particularmente en contextos caracterizados por disponibilidad limitada, ruido y alta variabilidad de datos.

El trabajo tendrá un esfuerzo preliminar estimado de 600 horas de dedicación y un costo estimado de \$ 24.000.000 (pesos argentinos), incluyendo investigación bibliográfica, diseño, experimentación, validación y elaboración de la memoria final. Como parte del trabajo podrá contemplarse, de resultar factible, una validación experimental complementaria en entorno controlado.

Se adjunta a la presente acta la planificación inicial.

Dr. Ing. Ariel Lutenberg
Director posgrado FIUBA

Nombre del cliente
Empresa del cliente

PhD. Ms. Camilo Enrique Argoty Pulido
Director del Trabajo Final

1. Descripción técnica-conceptual del proyecto a realizar

El presente proyecto se desarrolla en el marco del trabajo final de la Maestría en Inteligencia Artificial de la Facultad de Ingeniería de la Universidad de Buenos Aires y aborda una problemática relevante dentro del ámbito de la agricultura digital: la detección temprana de condiciones de estrés hídrico en cultivos hortícolas mediante técnicas de inteligencia artificial orientadas a mejorar la robustez predictiva.

La problemática abordada surge como continuidad del trabajo desarrollado en la asignatura Agricultura Digital, en la que se identificó que el manejo del riego en entornos hortícolas continúa dependiendo, en numerosos contextos productivos, de observación manual, experiencia empírica y reglas operativas estáticas. Este enfoque puede conducir tanto a déficit hídrico como a sobre-riego, lo que genera impactos negativos sobre el rendimiento productivo, la calidad comercial del cultivo y la eficiencia en el uso de recursos hídricos y energéticos.

El estrés hídrico constituye una condición fisiológica crítica que ocurre cuando la disponibilidad de agua resulta insuficiente para sostener adecuadamente los procesos metabólicos de la planta. Sus efectos incluyen reducción del crecimiento vegetativo, disminución del rendimiento y deterioro de la calidad comercial. De manera complementaria, el exceso de riego también puede producir consecuencias adversas, tales como desperdicio de agua, mayor consumo energético y aumento del riesgo sanitario asociado a enfermedades radiculares o fúngicas.

Durante los últimos años, la agricultura de precisión ha impulsado el uso de sensores, monitoreo remoto y herramientas analíticas orientadas a mejorar la toma de decisiones agronómicas. Sin embargo, la adopción efectiva de soluciones inteligentes en explotaciones hortícolas de pequeña y mediana escala continúa enfrentando desafíos significativos. Entre los principales obstáculos se destacan la escasez de datos históricos etiquetados, la alta variabilidad ambiental y productiva entre campañas y la presencia de ruido o anomalías en las mediciones provenientes de sensores.

En este contexto, el presente trabajo propone investigar de qué manera técnicas de inteligencia artificial pueden mejorar la robustez, adaptabilidad y capacidad predictiva de sistemas de detección temprana de estrés hídrico. La contribución principal del proyecto no se centra en el sensado IoT en sí mismo, sino en el análisis de mecanismos de inteligencia artificial orientados a superar limitaciones habituales en escenarios de datos agrícolas reales.

Uno de los desafíos centrales identificados corresponde a la disponibilidad limitada de datos históricos suficientemente representativos para entrenar modelos predictivos robustos. Para abordar esta limitación se analizará el uso de técnicas de generación de datos sintéticos, con el objetivo de complementar datasets reales y reducir el problema de *cold start* durante el entrenamiento inicial.

Adicionalmente, se incorporará un componente de detección de anomalías destinado a identificar lecturas atípicas, ruido sensorial o fallas de medición que puedan comprometer la confiabilidad del sistema. Complementariamente, se evaluará la incorporación de un mecanismo de retroalimentación humana mediante el que el usuario podrá validar o corregir alertas emitidas por el sistema, lo que generará información útil para la recalibración progresiva del modelo predictivo.

Como estrategia complementaria de validación experimental, y únicamente en caso de resultar técnicamente viable dentro de las restricciones de tiempo y recursos del proyecto, podrá evaluarse la implementación de una prueba de concepto de escala reducida sobre una unidad de cultivo instrumentada con sensores de humedad de suelo. Esta instancia permitiría validar

experimentalmente el flujo de captura de datos, procesamiento, predicción, generación de alertas y captura de retroalimentación humana en un entorno controlado.

La hipótesis de investigación que guía este trabajo sostiene que la incorporación de técnicas de inteligencia artificial, particularmente generación de datos sintéticos, modelado predictivo, detección de anomalías y retroalimentación humana, puede mejorar la capacidad de detección temprana de condiciones de estrés hídrico en contextos caracterizados por disponibilidad limitada, ruido y alta variabilidad de datos, respecto de enfoques tradicionales basados principalmente en observación empírica o reglas de riego estáticas.

En la figura 1 se presenta el diagrama conceptual de la arquitectura del sistema. El esquema muestra el flujo general de procesamiento de los datos. El proceso comienza con la captura de datos desde el cultivo, seguida por las etapas de preprocesamiento y control de calidad de las mediciones. Posteriormente, los datos son procesados por los módulos de inteligencia artificial para la generación de datos sintéticos, la detección de anomalías y la predicción temprana de estrés hídrico. Finalmente, el sistema genera alertas e incorpora retroalimentación humana para favorecer la recalibración progresiva del modelo.




Figura 1. Diagrama de arquitectura conceptual.

Como resultado esperado, se busca obtener una evaluación fundamentada de la factibilidad técnica y práctica del enfoque propuesto, una arquitectura conceptual de referencia y evidencia experimental inicial que permita establecer el potencial de futuras implementaciones de mayor escala dentro del sector hortícola.

2. Identificación y análisis de los interesados

Cuadro 1. Identificación de los interesados

Rol	Nombre y Apellido	Organización	Puesto
Auspiciante	FIUBA	Universidad de Buenos Aires	Institución académica
Responsable	Esp. Lic. Gustavo Julián Rivas	FIUBA	Alumno
Orientador	Dr. Camilo Enrique Argoty Pulido	FIUBA / Externo	Director del trabajo final
Colaboradores	Especialistas en agricultura digital	A definir	Expertos de dominio
Usuario final	Productores hortícolas	Sector agropecuario	Usuarios potenciales
Interesados sectoriales	Cámaras y asociaciones hortícolas	A definir	Referentes sectoriales

Las principales características de los interesados identificados son las siguientes:

- Auspiciante (FIUBA): responsable de evaluar el rigor metodológico, la calidad científica y la contribución académica del trabajo dentro del campo de la inteligencia artificial aplicada.
- Responsable del proyecto: encargado de la planificación, investigación bibliográfica, diseño experimental, análisis de resultados y elaboración de la memoria final.
- Director del trabajo final: brinda acompañamiento metodológico y orientación técnica durante el desarrollo del proyecto. Colaborará en la validación conceptual y revisión de avances.
- Colaboradores y expertos de dominio: aportan conocimiento agronómico y contextual sobre producción hortícola, manejo hídrico y problemáticas operativas del sector.
- Usuarios potenciales e interesados sectoriales: representan a productores y técnicos agrícolas que podrían beneficiarse de futuras soluciones derivadas de esta investigación y contribuyen a validar su relevancia práctica.

3. Propósito del proyecto

Investigar y evaluar cómo distintas técnicas de inteligencia artificial pueden contribuir a mejorar la detección temprana de condiciones de estrés hídrico en cultivos hortícolas. En particular, se analizará el aporte de la generación de datos sintéticos, el modelado predictivo, la detección de anomalías y los mecanismos de retroalimentación humana en escenarios caracterizados por disponibilidad limitada, ruido y alta variabilidad de los datos. El propósito final es evaluar su potencial como soporte para la toma de decisiones de riego.

4. Alcance del proyecto

El presente proyecto incluye:

- La revisión bibliográfica del estado del arte en agricultura digital, agricultura de precisión e inteligencia artificial aplicada al agro.
- El análisis de variables agronómicas relevantes para la detección temprana de estrés hídrico.
- La investigación y evaluación comparativa de técnicas de inteligencia artificial aplicables al problema, incluyendo modelos predictivos supervisados y, de resultar pertinente, arquitecturas de mayor complejidad.
- El análisis de técnicas de generación de datos sintéticos para escenarios de escasez de datos históricos.
- El estudio de algoritmos de detección de anomalías orientados a mejorar la confiabilidad del sistema.
- El diseño conceptual de una arquitectura integral de inteligencia artificial aplicada al problema.
- El diseño de un mecanismo de retroalimentación humana orientado a la recalibración progresiva del modelo.
- La validación experimental preliminar del enfoque propuesto mediante simulaciones, datasets disponibles o entornos controlados.
- De resultar factible, la implementación opcional de una prueba de concepto física de escala reducida.
- La elaboración de conclusiones y recomendaciones para futuras implementaciones de mayor escala.

El presente proyecto no incluye:

- La implementación productiva de una solución comercial.
- El desarrollo de hardware IoT propietario.
- El despliegue operativo en explotaciones agrícolas reales de gran escala.
- La automatización física del sistema de riego.
- La validación agronómica longitudinal sobre múltiples campañas productivas.
- La generalización estadística de resultados a toda la producción hortícola.

5. Supuestos del proyecto

Para el desarrollo del presente proyecto se supone que:

- La problemática del estrés hídrico en cultivos hortícolas constituye un problema relevante y suficientemente documentado en la literatura y en antecedentes académicos previos.
- Será posible acceder a bibliografía científica, datasets públicos y fuentes de información adecuadas para sustentar la investigación.
- Técnicas de inteligencia artificial podrán capturar patrones predictivos relevantes vinculados al estrés hídrico.
- La generación de datos sintéticos constituye una alternativa técnicamente viable para mitigar escenarios de escasez de datos históricos.
- Los algoritmos de detección de anomalías podrán contribuir a mejorar la robustez del sistema frente a ruido y lecturas atípicas.
- La retroalimentación humana podrá aportar información útil para recalibrar progresivamente el modelo.
- En caso de realizarse una prueba de concepto física, será posible contar con la infraestructura mínima necesaria para su ejecución.
- La infraestructura computacional y tecnológica disponible será suficiente para realizar análisis y experimentación preliminar.

6. Product Backlog

El product backlog organiza el trabajo del proyecto en un conjunto de épicas e historias de usuario que representan los principales entregables necesarios para desarrollar y validar la arquitectura de inteligencia artificial propuesta. Cada historia de usuario define una capacidad funcional o un resultado verificable que contribuye al cumplimiento de los objetivos del proyecto y a la contrastación de la hipótesis de investigación.

La estimación del esfuerzo relativo se expresa mediante *story points*, utilizando la sucesión de Fibonacci (1, 2, 3, 5, 8 y 13). La asignación considera la complejidad técnica, el esfuerzo de investigación, el desarrollo experimental y las actividades de validación asociadas a cada entregable.

- Épica 1. Fundamentación científica y preparación de la información
Objetivo: establecer las bases científicas del proyecto y preparar la información necesaria para el desarrollo de la arquitectura de inteligencia artificial.
 - Historia de usuario 1. Estado del arte y comprensión del dominio
Como responsable del proyecto, quiero disponer de un estado del arte sobre la aplicación de técnicas de inteligencia artificial para la detección temprana de estrés hídrico en cultivos hortícolas, para fundamentar las decisiones de diseño de la arquitectura propuesta.

Prioridad: alta.

Story points: 8.

Entregable esperado: estado del arte y marco conceptual documentados.

- Historia de usuario 2. Preparación del conjunto experimental de datos

Como responsable del proyecto, quiero disponer de fuentes de datos caracterizadas y preparadas, para establecer la información que utilizará la arquitectura y garantizar la reproducibilidad de la experimentación.

Prioridad: alta.

Story points: 8.

Entregable esperado: fuentes de datos caracterizadas, proceso de preparación documentado y conjunto experimental preparado.

■ Épica 2. Desarrollo del núcleo de inteligencia artificial

Objetivo: implementar los componentes principales de la arquitectura responsables del procesamiento de la información y de la generación de alertas tempranas.

- Historia de usuario 3. Implementación del componente de calidad y robustez de datos
Como responsable del proyecto, quiero disponer de un componente que incorpore mecanismos de preparación de datos, detección de anomalías y generación de datos sintéticos, para mejorar la calidad y representatividad de la información utilizada durante el entrenamiento y la evaluación de los modelos.

Prioridad: alta.

Story points: 13.

Entregable esperado: componente de calidad y robustez implementado e integrado con el flujo de procesamiento.

- Historia de usuario 4. Implementación del componente de modelado predictivo
Como responsable del proyecto, quiero disponer de un componente de ingeniería de variables y modelado predictivo, para estimar la evolución de las condiciones hídricas del cultivo y generar alertas tempranas.

Prioridad: alta.

Story points: 13.

Entregable esperado: componente de modelado predictivo integrado con la generación de alertas.

■ Épica 3. Integración y mejora de la arquitectura

Objetivo: integrar los componentes desarrollados e incorporar mecanismos que permitan mejorar progresivamente el desempeño de la arquitectura.

- Historia de usuario 5. Implementación del mecanismo de retroalimentación humana
Como responsable del proyecto, quiero disponer de un mecanismo que permita validar las alertas emitidas y registrar observaciones del usuario, para realizar la recalibración supervisada del modelo cuando resulte necesario.

Prioridad: alta.

Story points: 8.

Entregable esperado: mecanismo de retroalimentación humana integrado y documentado.

- Historia de usuario 6. Integración de la arquitectura experimental

Como responsable del proyecto, quiero integrar todos los componentes desarrollados, para disponer de un flujo completo de procesamiento y generación de alertas tempranas.

Prioridad: alta.

Story points: 5.

Entregable esperado: arquitectura experimental integrada y operativa.

- Épica 4. Evaluación experimental

Objetivo: obtener evidencia experimental que permita evaluar la arquitectura y contrastar la hipótesis de investigación.

- Historia de usuario 7. Diseño y ejecución del plan experimental

Como responsable del proyecto, quiero ejecutar un conjunto de experimentos controlados, para evaluar la arquitectura en distintos escenarios de disponibilidad y calidad de datos.

Prioridad: alta.

Story points: 8.

Entregable esperado: plan experimental ejecutado y resultados registrados.

- Historia de usuario 8. Análisis de resultados y contrastación de la hipótesis

Como responsable del proyecto, quiero analizar los resultados obtenidos durante la experimentación, para determinar el aporte de los distintos componentes de la arquitectura y contrastar la hipótesis de investigación.

Prioridad: alta.

Story points: 8.

Entregable esperado: análisis de resultados, conclusiones y validación de la hipótesis.

7. Criterios de aceptación de historias de usuario

Los criterios de aceptación se organizan siguiendo la misma estructura de épicas e historias de usuario definida en el product backlog. Cada historia de usuario se considerará completada cuando exista evidencia suficiente de que el entregable asociado ha sido fundamentado, diseñado, implementado, validado y documentado, según corresponda.

Épica 1. Fundamentación científica y preparación de la información

Historia de usuario 1. Estado del arte y comprensión del dominio

La historia de usuario se considerará completada cuando:

- Se identificaron y analizaron antecedentes científicos y técnicos relevantes para el problema de investigación.
- Se documentaron las principales técnicas de inteligencia artificial aplicadas a la detección temprana de estrés hídrico.
- Se justificó la selección de las técnicas que serán evaluadas durante la investigación.
- El estado del arte y el marco conceptual quedaron documentados.

Historia de usuario 2. Preparación del conjunto experimental de datos

La historia de usuario se considerará completada cuando:

- Se identificaron y documentaron las fuentes de datos seleccionadas.
- Se definió y documentó el proceso de preparación de datos.
- Se obtuvo un conjunto experimental apto para el desarrollo y la evaluación de la arquitectura.
- El procedimiento puede reproducirse a partir de la documentación generada.

Épica 2. Desarrollo del núcleo de inteligencia artificial

Historia de usuario 3. Implementación del componente de calidad y robustez de datos

La historia de usuario se considerará completada cuando:

- El componente procesa correctamente los datos de entrada.
- La detección de anomalías se ejecuta sobre el conjunto experimental.
- La generación de datos sintéticos se integra al flujo de procesamiento.
- El componente genera información apta para el modelado predictivo.

Historia de usuario 4. Implementación del componente de modelado predictivo

La historia de usuario se considerará completada cuando:

- El componente implementa la ingeniería de variables definida para el proyecto.
- El modelo predictivo puede entrenarse utilizando el conjunto experimental.
- El componente genera predicciones y alertas tempranas de estrés hídrico.
- Las métricas de desempeño quedan registradas para su evaluación.

Épica 3. Integración y mejora de la arquitectura

Historia de usuario 5. Implementación del mecanismo de retroalimentación humana

La historia de usuario se considerará completada cuando:

- El mecanismo permite registrar la validación de las alertas emitidas.
- Las observaciones registradas pueden incorporarse al proceso de recalibración supervisada.
- El componente se integra correctamente con la arquitectura propuesta.
- La información registrada queda disponible para la evaluación experimental.

Historia de usuario 6. Integración de la arquitectura experimental

La historia de usuario se considerará completada cuando:

- Todos los componentes de la arquitectura intercambian información correctamente.
- El flujo completo de procesamiento se ejecuta sin errores.
- La arquitectura genera alertas tempranas utilizando todos los componentes integrados.
- La arquitectura queda preparada para la ejecución del plan experimental.

Épica 4. Evaluación experimental

Historia de usuario 7. Diseño y ejecución del plan experimental

La historia de usuario se considerará completada cuando:

- Se definió el protocolo experimental.
- Los experimentos pueden ejecutarse de forma reproducible.
- Los resultados obtenidos quedan registrados y organizados para su análisis.
- El protocolo contempla la comparación de las configuraciones definidas para la investigación.

Historia de usuario 8. Análisis de resultados y contrastación de la hipótesis

La historia de usuario se considerará completada cuando:

- Se comparan las distintas configuraciones evaluadas durante la experimentación.
- Se analiza el aporte de los componentes incorporados a la arquitectura.
- Se elaboran conclusiones fundamentadas a partir de la evidencia experimental obtenida.
- Se determina si los resultados permiten contrastar la hipótesis de investigación.

8. Fases de CRISP-DM

La metodología CRISP-DM se adopta como marco metodológico para organizar el proceso de investigación, diseño, implementación experimental y validación de la arquitectura de inteligencia artificial propuesta. Cada una de sus fases se adapta al proyecto con el propósito de mantener la trazabilidad entre la hipótesis de investigación, la arquitectura conceptual, el product backlog, los criterios de aceptación y la evidencia experimental obtenida durante la ejecución del trabajo.

1. Comprensión del problema

En esta fase se definirá el marco de investigación orientado a evaluar una arquitectura de inteligencia artificial para la detección temprana de estrés hídrico en cultivos hortícolas. Se utilizará la información conceptual y técnica relevada sobre agricultura digital, estrés hídrico, disponibilidad limitada de datos, ruido sensorial, variabilidad ambiental y técnicas de aprendizaje automático aplicables al dominio.

La validación experimental comparará distintas configuraciones de la arquitectura con el propósito de cuantificar el aporte de la generación de datos sintéticos, la detección de anomalías y la retroalimentación humana sobre el desempeño del modelo predictivo. Como resultado de esta fase se obtendrán el estado del arte, el marco conceptual, la formulación del problema, la hipótesis de investigación y los criterios metodológicos que orientarán el diseño experimental.

Esta fase corresponde a las actividades definidas en la épica 1 del product backlog.

2. Comprensión de los datos

La fuente principal de información estará constituida por *datasets* públicos relacionados con humedad del suelo, variables meteorológicas y condiciones de riego provenientes de repositorios científicos y plataformas de datos abiertos. Estos conjuntos serán identificados, caracterizados y documentados en función de su origen, cobertura temporal, variables disponibles, frecuencia de registro, estructura, calidad, restricciones de uso y pertinencia para el problema de predicción seleccionado.

Los conjuntos de datos se complementarán, cuando resulte posible, con información climática histórica correspondiente al período analizado. Se incorporarán variables como temperatura, humedad relativa, precipitación, radiación solar, velocidad del viento y evapotranspiración de referencia, con el propósito de enriquecer la representación de las condiciones ambientales asociadas al estrés hídrico.

La prueba de concepto instrumentada con sensores de humedad del suelo constituye una actividad complementaria y opcional destinada únicamente a validar el funcionamiento integral de la arquitectura. Esta actividad no representa la fuente principal de datos del proyecto ni modifica el alcance metodológico de la investigación.

Como resultado de esta fase se obtendrán las fuentes de datos seleccionadas, su caracterización técnica, las restricciones identificadas y la documentación necesaria para reproducir el proceso de preparación posterior. Esta fase corresponde a las actividades definidas en la épica 1 del product backlog.

3. Preparación de los datos

En esta fase los datos serán integrados, depurados, normalizados y transformados antes de su utilización en la arquitectura experimental. Se ejecutarán actividades de limpieza de registros, tratamiento de valores faltantes, detección de inconsistencias, alineación temporal, selección de variables, construcción de variables derivadas y organización de los conjuntos destinados al entrenamiento, la validación y la prueba.

La arquitectura incorporará un componente de detección de anomalías y un componente de generación de datos sintéticos con el propósito de mejorar la robustez del conjunto de entrenamiento frente a escenarios de disponibilidad limitada de datos. La detección de anomalías permitirá identificar lecturas atípicas o inconsistentes, mientras que la generación de datos sintéticos permitirá complementar el conjunto experimental sin reemplazar la información real utilizada como referencia.

Como resultado de esta fase se obtendrá un conjunto experimental preparado, trazable y apto para el desarrollo y la evaluación de la arquitectura. Esta fase corresponde a las actividades definidas en la historia de usuario 3 de la épica 2.

4. Modelado

En esta fase se implementará la arquitectura experimental mediante componentes de calidad y robustez de datos, ingeniería de variables, modelado predictivo, generación de alertas tempranas, retroalimentación humana y recalibración supervisada. Los componentes se organizarán de acuerdo con la arquitectura conceptual presentada, de modo que cada módulo intercambie información de forma explícita y verificable.

Se implementará una configuración *baseline* de la arquitectura y posteriormente se evaluarán distintas técnicas de aprendizaje automático seleccionadas de acuerdo con las características de los datos disponibles. La selección de técnicas considerará el tipo de variable objetivo, el volumen de datos, la calidad de las etiquetas, la estructura temporal de las mediciones y la necesidad de interpretar el desempeño del modelo en el contexto agronómico.

La selección del modelo final dependerá del desempeño experimental obtenido y no de la complejidad del algoritmo utilizado. Como resultado de esta fase se obtendrá un componente predictivo capaz de entrenarse con el conjunto experimental, generar predicciones, emitir alertas tempranas y registrar métricas de desempeño para su evaluación posterior.

Esta fase corresponde a las actividades definidas en las historias de usuario 4 y 5.

5. Evaluación

La experimentación comprenderá, como mínimo, las siguientes configuraciones: arquitectura base, arquitectura base con generación de datos sintéticos, arquitectura base con detección de anomalías, arquitectura completa con generación de datos sintéticos, detección de anomalías y retroalimentación humana.

Cada configuración será comparada utilizando métricas apropiadas para el problema de predicción seleccionado y, cuando corresponda, indicadores asociados a la generación de alertas tempranas. Se registrarán los resultados obtenidos, las configuraciones utilizadas, los parámetros principales, las métricas de desempeño y las observaciones derivadas del análisis experimental.

Esta fase permitirá cuantificar el aporte individual y conjunto de cada componente incorporado a la arquitectura. Los resultados obtenidos permitirán analizar el efecto de la generación de datos sintéticos, la detección de anomalías y la retroalimentación humana sobre el desempeño predictivo y sobre la capacidad de generar alertas tempranas de estrés hídrico.

Como resultado de esta fase se obtendrán los resultados experimentales organizados, la comparación de configuraciones, el análisis del aporte de cada componente y la evidencia necesaria para contrastar la hipótesis de investigación. Esta fase corresponde a las historias de usuario 5, 6, 7 y 8.

6. Despliegue e integración experimental

La arquitectura será implementada como un prototipo experimental ejecutable en un entorno local, organizado en módulos desacoplados que permitan reproducir los experimentos y registrar los resultados obtenidos. El prototipo integrará el flujo completo de preparación de datos, detección de anomalías, generación de datos sintéticos, ingeniería de variables, predicción, generación de alertas, retroalimentación humana y recalibración supervisada.

La prueba de concepto física, en caso de desarrollarse, se utilizará exclusivamente para validar el flujo completo de adquisición de datos, procesamiento, predicción y generación de alertas, sin modificar el alcance principal del proyecto. Esta validación complementaria

permitirá verificar la integración funcional de la arquitectura en un entorno controlado, pero no reemplazará la evaluación experimental basada en las fuentes de datos principales.

Como resultado de esta fase se obtendrá una arquitectura experimental integrada, ejecutable y documentada, preparada para reproducir los experimentos definidos y conservar la trazabilidad de los resultados obtenidos. Esta fase corresponde a la historia de usuario 6.

9. Desglose del trabajo en tareas

Las historias de usuario definidas en el product backlog se descomponen en tareas técnicas con el propósito de facilitar la planificación, el seguimiento y el control del trabajo necesario para desarrollar la arquitectura de inteligencia artificial propuesta. Cada tarea incluye una estimación de esfuerzo y un nivel de prioridad que servirán como base para la planificación de los sprints y del cronograma general del proyecto.

Historia de usuario	Tarea técnica	Estimación	Prioridad
HU1	Definir el protocolo de revisión bibliográfica	6 h	Alta
HU1	Definir términos, sinónimos y cadenas de búsqueda en español e inglés	6 h	Alta
HU1	Definir criterios de inclusión, exclusión y período de análisis	6 h	Alta
HU1	Ejecutar y registrar búsquedas en Scopus y Web of Science	8 h	Alta
HU1	Ejecutar y registrar búsquedas en IEEE Xplore	8 h	Alta
HU1	Buscar antecedentes agronómicos en AGRIS, SciELO y Horticultura Argentina	6 h	Alta
HU1	Revisar documentación técnica del INTA, FAO y organismos académicos nacionales	6 h	Media
HU1	Consolidar referencias y eliminar registros duplicados	6 h	Alta
HU1	Evaluar títulos y resúmenes según los criterios definidos	8 h	Alta
HU1	Analizar trabajos sobre modelado predictivo de estrés hídrico	8 h	Alta
HU1	Analizar trabajos sobre detección de anomalías y datos sintéticos	8 h	Alta
HU1	Analizar trabajos sobre retroalimentación humana y recalibración	6 h	Alta
HU1	Elaborar la matriz comparativa de antecedentes	8 h	Alta
HU1	Identificar vacancias y criterios para el diseño de la arquitectura	6 h	Alta
HU1	Redactar el estado del arte y el marco conceptual	8 h	Alta
HU1	Revisar la trazabilidad de citas, antecedentes y decisiones metodológicas	6 h	Media
Subtotal HU1		110 h	
HU2	Definir las variables agronómicas, climáticas y temporales requeridas	6 h	Alta
HU2	Identificar conjuntos de datos asociados a publicaciones científicas	8 h	Alta
HU2	Relevar datos disponibles en SMN, NASA POWER y Copernicus	8 h	Alta
HU2	Evaluar metadatos, licencias, procedencia y restricciones de uso	6 h	Alta
HU2	Descargar y organizar muestras representativas de las fuentes candidatas	6 h	Alta
HU2	Homogeneizar formatos, unidades, frecuencias y zonas horarias	8 h	Alta
HU2	Analizar cobertura temporal, granularidad e integridad de las fuentes	8 h	Alta
HU2	Definir criterios de selección y descarte de fuentes de datos	6 h	Alta
HU2	Implementar el procedimiento reproducible de ingestión y consolidación	8 h	Alta

Historia de usuario	Tarea técnica	Estimación	Prioridad
HU2	Documentar el diccionario de datos, procedencia y limitaciones	6 h	Media
Subtotal HU2		70 h	
HU3	Analizar distribuciones, rangos y tipos de las variables	6 h	Alta
HU3	Definir reglas de calidad y rangos agronómicos esperados	6 h	Alta
HU3	Implementar el reporte de valores faltantes, duplicados y atípicos	6 h	Alta
HU3	Implementar el tratamiento de valores faltantes	6 h	Alta
HU3	Implementar normalización, codificación y alineación temporal	6 h	Alta
HU3	Preparar particiones sin contaminación entre entrenamiento y evaluación	4 h	Alta
HU3	Seleccionar métodos candidatos para detección de anomalías	4 h	Alta
HU3	Implementar el método base de detección de anomalías	8 h	Alta
HU3	Evaluar el comportamiento del detector de anomalías	6 h	Alta
HU3	Seleccionar técnicas candidatas para generación de datos sintéticos	4 h	Alta
HU3	Implementar un prototipo de generación de datos sintéticos	8 h	Alta
HU3	Evaluar similitud estadística y utilidad predictiva de los datos sintéticos	6 h	Alta
HU3	Integrar las transformaciones en un flujo reproducible	6 h	Alta
HU3	Documentar decisiones, parámetros y limitaciones del componente	4 h	Media
Subtotal HU3		80 h	
HU4	Definir la variable objetivo y el horizonte de anticipación	6 h	Alta
HU4	Identificar variables predictoras, retardos y ventanas temporales	6 h	Alta
HU4	Implementar la ingeniería de variables temporales y agronómicas	8 h	Alta
HU4	Evaluar relevancia de variables y posibles fugas de información	6 h	Alta
HU4	Definir modelos de referencia y modelos candidatos	6 h	Alta
HU4	Implementar el modelo de referencia	6 h	Alta
HU4	Implementar el flujo de entrenamiento para los modelos candidatos	8 h	Alta
HU4	Implementar el esquema de validación temporal o cruzada	8 h	Alta
HU4	Ejecutar el entrenamiento inicial de los modelos candidatos	6 h	Alta
HU4	Ejecutar el ajuste de hiperparámetros	8 h	Media
HU4	Comparar desempeño, estabilidad y complejidad de los modelos	6 h	Alta
HU4	Definir e implementar la lógica de generación de alertas tempranas	8 h	Alta
HU4	Analizar errores de predicción y alertas incorrectas	4 h	Alta
HU4	Documentar configuración, métricas y limitaciones del modelo	4 h	Media
Subtotal HU4		90 h	
HU5	Definir casos de uso y estados de validación de las alertas	5 h	Alta
HU5	Diseñar el modelo de datos para registrar retroalimentación	6 h	Alta
HU5	Diseñar el flujo de interacción entre alerta, usuario y modelo	5 h	Media
HU5	Implementar el registro de validaciones de alertas	8 h	Alta
HU5	Implementar el registro de correcciones y observaciones	6 h	Alta
HU5	Integrar la retroalimentación con los registros de predicción	5 h	Alta
HU5	Definir reglas para seleccionar observaciones de recalibración	4 h	Alta
HU5	Implementar una prueba de recalibración supervisada	6 h	Alta
Subtotal HU5		45 h	
HU6	Definir contratos, entradas y salidas entre componentes	6 h	Alta
HU6	Integrar el componente de calidad con el componente predictivo	8 h	Alta
HU6	Integrar las alertas con el mecanismo de retroalimentación	7 h	Alta
HU6	Configurar la ejecución completa de la arquitectura	6 h	Alta
HU6	Ejecutar pruebas funcionales de integración	4 h	Alta
HU6	Resolver incidencias y documentar los ajustes de integración	4 h	Media
Subtotal HU6		35 h	

Historia de usuario	Tarea técnica	Estimación	Prioridad
HU7	Definir preguntas experimentales y factores de evaluación	6 h	Alta
HU7	Definir escenarios de escasez, ruido y variabilidad de datos	8 h	Alta
HU7	Definir configuraciones comparativas y pruebas de ablación	6 h	Alta
HU7	Definir métricas y criterios de evaluación	4 h	Alta
HU7	Definir particiones, semillas y cantidad de repeticiones	4 h	Alta
HU7	Implementar el procedimiento automatizado de experimentación	8 h	Alta
HU7	Configurar el registro de parámetros, versiones y resultados	6 h	Alta
HU7	Ejecutar una prueba piloto del protocolo experimental	6 h	Alta
HU7	Ejecutar experimentos con modelos de referencia	8 h	Alta
HU7	Ejecutar experimentos con mecanismos de robustez integrados	8 h	Alta
HU7	Verificar integridad y reproducibilidad de los experimentos	6 h	Alta
Subtotal HU7		70 h	
HU8	Consolidar los resultados de todas las ejecuciones experimentales	6 h	Alta
HU8	Identificar ejecuciones incompletas o inconsistentes	4 h	Alta
HU8	Calcular métricas agregadas y medidas de dispersión	8 h	Alta
HU8	Comparar el enfoque de referencia con la arquitectura propuesta	8 h	Alta
HU8	Analizar el aporte de la detección de anomalías y los datos sintéticos	8 h	Alta
HU8	Evaluar el efecto de la retroalimentación y la recalibración	6 h	Alta
HU8	Analizar falsos positivos, falsos negativos y errores relevantes	6 h	Alta
HU8	Analizar el desempeño bajo escenarios de escasez de datos	8 h	Alta
HU8	Analizar el desempeño bajo escenarios de ruido y variabilidad	8 h	Alta
HU8	Evaluar robustez, estabilidad y compromisos entre métricas	6 h	Alta
HU8	Contrastar los resultados con la hipótesis de investigación	8 h	Alta
HU8	Identificar limitaciones y amenazas a la validez	6 h	Alta
HU8	Redactar la sección de resultados experimentales	8 h	Alta
HU8	Redactar la discusión y las conclusiones	6 h	Alta
HU8	Consolidar tablas, figuras, referencias y evidencias	4 h	Media
Subtotal HU8		100 h	
Total general		600 h	

10. Planificación de Sprints

La planificación de los sprints organiza la ejecución del proyecto a partir de las historias de usuario y las tareas técnicas definidas en el product backlog. Cada sprint agrupa actividades relacionadas con un objetivo específico de la investigación y genera entregables verificables que permiten monitorear el avance del proyecto. La distribución propuesta mantiene la trazabilidad con las historias de usuario, los criterios de aceptación, las fases de CRISP-DM y el desglose de tareas definido previamente. Asimismo, contempla actividades de documentación continua, de modo que la memoria final se construya progresivamente durante el desarrollo del proyecto y no únicamente en la etapa de cierre.

El Sprint 0 registra las actividades de planificación ya completadas durante la elaboración del plan del proyecto. Sus 40 horas se presentan como antecedente de gestión y no se adicionan a la línea base de 600 horas correspondiente al desarrollo de las historias de usuario HU1 a HU8.

Cuadro 3. Planificación de sprints

Sprint	Historia de usuario	Tarea	Horas	Responsable	Avance
Sprint 0	Planificación	Elaboración del acta de constitución	8 h	Gustavo Rivas	100 %

Sprint	Historia de usuario	Tarea	Horas	Responsable	Avance
Sprint 0	Planificación	Definición del propósito y alcance	5 h	Gustavo Rivas	100 %
Sprint 0	Planificación	Formulación de la hipótesis	5 h	Gustavo Rivas	100 %
Sprint 0	Planificación	Elaboración del product backlog	6 h	Gustavo Rivas	100 %
Sprint 0	Planificación	Definición de los criterios de aceptación	6 h	Gustavo Rivas	100 %
Sprint 0	Planificación	Adaptación de la metodología CRISP-DM	5 h	Gustavo Rivas	100 %
Sprint 0	Planificación	Estimación de tareas, planificación de sprints y elaboración del cronograma	5 h	Gustavo Rivas	100 %
Sprint 1	HU1	Definir el protocolo de revisión bibliográfica	6 h	Gustavo Rivas	0 %
Sprint 1	HU1	Definir términos, sinónimos y cadenas de búsqueda en español e inglés	6 h	Gustavo Rivas	0 %
Sprint 1	HU1	Definir criterios de inclusión, exclusión y período de análisis	6 h	Gustavo Rivas	0 %
Sprint 1	HU1	Ejecutar y registrar búsquedas en Scopus y Web of Science	8 h	Gustavo Rivas	0 %
Sprint 1	HU1	Ejecutar y registrar búsquedas en IEEE Xplore	8 h	Gustavo Rivas	0 %
Sprint 1	HU1	Buscar antecedentes agronómicos en AGRIS, SciELO y Horticultura Argentina	6 h	Gustavo Rivas	0 %
Sprint 1	HU1	Revisar documentación técnica del INTA, FAO y organismos académicos nacionales	6 h	Gustavo Rivas	0 %
Sprint 1	HU1	Consolidar referencias y eliminar registros duplicados	6 h	Gustavo Rivas	0 %
Sprint 1	HU1	Evaluar títulos y resúmenes según los criterios definidos	8 h	Gustavo Rivas	0 %
Sprint 1	HU1	Analizar trabajos sobre modelado predictivo de estrés hídrico	8 h	Gustavo Rivas	0 %
Sprint 1	HU1	Analizar trabajos sobre detección de anomalías y datos sintéticos	8 h	Gustavo Rivas	0 %
Sprint 1	HU1	Analizar trabajos sobre retroalimentación humana y recalibración	6 h	Gustavo Rivas	0 %
Sprint 1	HU1	Elaborar la matriz comparativa de antecedentes	8 h	Gustavo Rivas	0 %
Sprint 1	HU1	Identificar vacancias y criterios para el diseño de la arquitectura	6 h	Gustavo Rivas	0 %
Sprint 1	HU1	Redactar el estado del arte y el marco conceptual	8 h	Gustavo Rivas	0 %
Sprint 1	HU1	Revisar la trazabilidad de citas, antecedentes y decisiones metodológicas	6 h	Gustavo Rivas	0 %
Sprint 2	HU2	Definir las variables agronómicas, climáticas y temporales requeridas	6 h	Gustavo Rivas	0 %
Sprint 2	HU2	Identificar conjuntos de datos asociados a publicaciones científicas	8 h	Gustavo Rivas	0 %
Sprint 2	HU2	Relevar datos disponibles en SMN, NASA POWER y Copernicus	8 h	Gustavo Rivas	0 %
Sprint 2	HU2	Evaluar metadatos, licencias, procedencia y restricciones de uso	6 h	Gustavo Rivas	0 %
Sprint 2	HU2	Descargar y organizar muestras representativas de las fuentes candidatas	6 h	Gustavo Rivas	0 %
Sprint 2	HU2	Homogeneizar formatos, unidades, frecuencias y zonas horarias	8 h	Gustavo Rivas	0 %

Sprint	Historia de usuario	Tarea	Horas	Responsable	Avance
Sprint 2	HU2	Analizar cobertura temporal, granularidad e integridad de las fuentes	8 h	Gustavo Rivas	0 %
Sprint 2	HU2	Definir criterios de selección y descarte de fuentes de datos	6 h	Gustavo Rivas	0 %
Sprint 2	HU2	Implementar el procedimiento reproducible de ingestión y consolidación	8 h	Gustavo Rivas	0 %
Sprint 2	HU2	Documentar el diccionario de datos, procedencia y limitaciones	6 h	Gustavo Rivas	0 %
Sprint 3	HU3	Analizar distribuciones, rangos y tipos de las variables	6 h	Gustavo Rivas	0 %
Sprint 3	HU3	Definir reglas de calidad y rangos agronómicos esperados	6 h	Gustavo Rivas	0 %
Sprint 3	HU3	Implementar el reporte de valores faltantes, duplicados y atípicos	6 h	Gustavo Rivas	0 %
Sprint 3	HU3	Implementar el tratamiento de valores faltantes	6 h	Gustavo Rivas	0 %
Sprint 3	HU3	Implementar normalización, codificación y alineación temporal	6 h	Gustavo Rivas	0 %
Sprint 3	HU3	Preparar particiones sin contaminación entre entrenamiento y evaluación	4 h	Gustavo Rivas	0 %
Sprint 3	HU3	Seleccionar métodos candidatos para detección de anomalías	4 h	Gustavo Rivas	0 %
Sprint 3	HU3	Implementar el método base de detección de anomalías	8 h	Gustavo Rivas	0 %
Sprint 3	HU3	Evaluar el comportamiento del detector de anomalías	6 h	Gustavo Rivas	0 %
Sprint 3	HU3	Seleccionar técnicas candidatas para generación de datos sintéticos	4 h	Gustavo Rivas	0 %
Sprint 3	HU3	Implementar un prototipo de generación de datos sintéticos	8 h	Gustavo Rivas	0 %
Sprint 3	HU3	Evaluar similitud estadística y utilidad predictiva de los datos sintéticos	6 h	Gustavo Rivas	0 %
Sprint 3	HU3	Integrar las transformaciones en un flujo reproducible	6 h	Gustavo Rivas	0 %
Sprint 3	HU3	Documentar decisiones, parámetros y limitaciones del componente	4 h	Gustavo Rivas	0 %
Sprint 4	HU4	Definir la variable objetivo y el horizonte de anticipación	6 h	Gustavo Rivas	0 %
Sprint 4	HU4	Identificar variables predictoras, retardos y ventanas temporales	6 h	Gustavo Rivas	0 %
Sprint 4	HU4	Implementar la ingeniería de variables temporales y agronómicas	8 h	Gustavo Rivas	0 %
Sprint 4	HU4	Evaluar relevancia de variables y posibles fugas de información	6 h	Gustavo Rivas	0 %
Sprint 4	HU4	Definir modelos de referencia y modelos candidatos	6 h	Gustavo Rivas	0 %
Sprint 4	HU4	Implementar el modelo de referencia	6 h	Gustavo Rivas	0 %
Sprint 4	HU4	Implementar el flujo de entrenamiento para los modelos candidatos	8 h	Gustavo Rivas	0 %
Sprint 4	HU4	Implementar el esquema de validación temporal o cruzada	8 h	Gustavo Rivas	0 %
Sprint 4	HU4	Ejecutar el entrenamiento inicial de los modelos candidatos	6 h	Gustavo Rivas	0 %
Sprint 4	HU4	Ejecutar el ajuste de hiperparámetros	8 h	Gustavo Rivas	0 %
Sprint 4	HU4	Comparar desempeño, estabilidad y complejidad de los modelos	6 h	Gustavo Rivas	0 %

Sprint	Historia de usuario	Tarea	Horas	Responsable	Avance
Sprint 4	HU4	Definir e implementar la lógica de generación de alertas tempranas	8 h	Gustavo Rivas	0 %
Sprint 4	HU4	Analizar errores de predicción y alertas incorrectas	4 h	Gustavo Rivas	0 %
Sprint 4	HU4	Documentar configuración, métricas y limitaciones del modelo	4 h	Gustavo Rivas	0 %
Sprint 5	HU5	Definir casos de uso y estados de validación de las alertas	5 h	Gustavo Rivas	0 %
Sprint 5	HU5	Diseñar el modelo de datos para registrar retroalimentación	6 h	Gustavo Rivas	0 %
Sprint 5	HU5	Diseñar el flujo de interacción entre alerta, usuario y modelo	5 h	Gustavo Rivas	0 %
Sprint 5	HU5	Implementar el registro de validaciones de alertas	8 h	Gustavo Rivas	0 %
Sprint 5	HU5	Implementar el registro de correcciones y observaciones	6 h	Gustavo Rivas	0 %
Sprint 5	HU5	Integrar la retroalimentación con los registros de predicción	5 h	Gustavo Rivas	0 %
Sprint 5	HU5	Definir reglas para seleccionar observaciones de recalibración	4 h	Gustavo Rivas	0 %
Sprint 5	HU5	Implementar una prueba de recalibración supervisada	6 h	Gustavo Rivas	0 %
Sprint 6	HU6	Definir contratos, entradas y salidas entre componentes	6 h	Gustavo Rivas	0 %
Sprint 6	HU6	Integrar el componente de calidad con el componente predictivo	8 h	Gustavo Rivas	0 %
Sprint 6	HU6	Integrar las alertas con el mecanismo de retroalimentación	7 h	Gustavo Rivas	0 %
Sprint 6	HU6	Configurar la ejecución completa de la arquitectura	6 h	Gustavo Rivas	0 %
Sprint 6	HU6	Ejecutar pruebas funcionales de integración	4 h	Gustavo Rivas	0 %
Sprint 6	HU6	Resolver incidencias y documentar los ajustes de integración	4 h	Gustavo Rivas	0 %
Sprint 7	HU7	Definir preguntas experimentales y factores de evaluación	6 h	Gustavo Rivas	0 %
Sprint 7	HU7	Definir escenarios de escasez, ruido y variabilidad de datos	8 h	Gustavo Rivas	0 %
Sprint 7	HU7	Definir configuraciones comparativas y pruebas de ablación	6 h	Gustavo Rivas	0 %
Sprint 7	HU7	Definir métricas y criterios de evaluación	4 h	Gustavo Rivas	0 %
Sprint 7	HU7	Definir particiones, semillas y cantidad de repeticiones	4 h	Gustavo Rivas	0 %
Sprint 7	HU7	Implementar el procedimiento automatizado de experimentación	8 h	Gustavo Rivas	0 %
Sprint 7	HU7	Configurar el registro de parámetros, versiones y resultados	6 h	Gustavo Rivas	0 %
Sprint 7	HU7	Ejecutar una prueba piloto del protocolo experimental	6 h	Gustavo Rivas	0 %
Sprint 7	HU7	Ejecutar experimentos con modelos de referencia	8 h	Gustavo Rivas	0 %
Sprint 7	HU7	Ejecutar experimentos con mecanismos de robustez integrados	8 h	Gustavo Rivas	0 %
Sprint 7	HU7	Verificar integridad y reproducibilidad de los experimentos	6 h	Gustavo Rivas	0 %
Sprint 8	HU8	Consolidar los resultados de todas las ejecuciones experimentales	6 h	Gustavo Rivas	0 %
Sprint 8	HU8	Identificar ejecuciones incompletas o inconsistentes	4 h	Gustavo Rivas	0 %

Sprint	Historia de usuario	Tarea	Horas	Responsable	Avance
Sprint 8	HU8	Calcular métricas agregadas y medidas de dispersión	8 h	Gustavo Rivas	0 %
Sprint 8	HU8	Comparar el enfoque de referencia con la arquitectura propuesta	8 h	Gustavo Rivas	0 %
Sprint 8	HU8	Analizar el aporte de la detección de anomalías y los datos sintéticos	8 h	Gustavo Rivas	0 %
Sprint 8	HU8	Evaluar el efecto de la retroalimentación y la recalibración	6 h	Gustavo Rivas	0 %
Sprint 9	HU8	Analizar falsos positivos, falsos negativos y errores relevantes	6 h	Gustavo Rivas	0 %
Sprint 9	HU8	Analizar el desempeño bajo escenarios de escasez de datos	8 h	Gustavo Rivas	0 %
Sprint 9	HU8	Analizar el desempeño bajo escenarios de ruido y variabilidad	8 h	Gustavo Rivas	0 %
Sprint 9	HU8	Evaluar robustez, estabilidad y compromisos entre métricas	6 h	Gustavo Rivas	0 %
Sprint 9	HU8	Contrastar los resultados con la hipótesis de investigación	8 h	Gustavo Rivas	0 %
Sprint 9	HU8	Identificar limitaciones y amenazas a la validez	6 h	Gustavo Rivas	0 %
Sprint 10	HU8	Redactar la sección de resultados experimentales	8 h	Gustavo Rivas	0 %
Sprint 10	HU8	Redactar la discusión y las conclusiones	6 h	Gustavo Rivas	0 %
Sprint 10	HU8	Consolidar tablas, figuras, referencias y evidencias	4 h	Gustavo Rivas	0 %

La planificación presentada organiza el desarrollo del proyecto desde las actividades iniciales de planificación hasta la elaboración de la memoria final y la preparación de la defensa. El Sprint 0 corresponde a la fase de planificación del proyecto y se considera completamente ejecutado, dado que sus entregables se materializan en el presente documento. Los sprints restantes reflejan el estado inicial de la ejecución del trabajo y presentan un avance del 0 %, manteniendo la coherencia con el estado actual del proyecto y la trazabilidad con las historias de usuario y entregables definidos en las secciones anteriores.

11. Diagrama de Gantt (sprints)

El cronograma organiza temporalmente las tareas definidas en la planificación de sprints del capítulo anterior. Se consideran once sprints en total, desde el Sprint 0 hasta el Sprint 10. Para asegurar la legibilidad de las 101 tareas, el diagrama de Gantt se presenta en cinco figuras consecutivas. Las actividades de planificación del Sprint 0 se diferencian visualmente de las tareas técnicas asociadas a las historias de usuario HU1 a HU8. Las barras representan la secuencia temporal y el esfuerzo estimado de cada tarea. Los meses se muestran en la parte superior de cada diagrama y las semanas se representan en el eje temporal inferior.

En la figura 2 se presentan las actividades de planificación y las tareas correspondientes a la revisión del estado del arte.

Cronograma detallado: Sprint 0 y Sprint 1

Inicio: 23/06/2026 · dedicación planificada: 28 h/semana · ejecución secuencial en días hábiles




Figura 2. Cronograma detallado del Sprint 0 y el Sprint 1.

En la figura 3 se presentan las tareas de preparación del conjunto experimental y de implementación del componente de calidad y robustez de datos.




Figura 3. Cronograma detallado del Sprint 2 y el Sprint 3.

En la figura 4 se presentan las tareas de modelado predictivo y de implementación del mecanismo de retroalimentación humana.




Figura 4. Cronograma detallado del Sprint 4 y el Sprint 5.

En la figura 5 se presentan las tareas de integración de la arquitectura y de ejecución del plan experimental.




Figura 5. Cronograma detallado del Sprint 6 y el Sprint 7.

En la figura 6 se presentan las tareas de análisis de resultados, contrastación de la hipótesis, redacción y cierre documental.




Figura 6. Cronograma detallado del Sprint 8, el Sprint 9 y el Sprint 10.

12. Gobernanza de datos

12.1. Cumplimiento normativo

Las variables ambientales y agronómicas utilizadas por la arquitectura incluyen humedad del suelo, temperatura, humedad ambiente, precipitaciones, eventos de riego y características del cultivo. Estas variables no constituyen, en principio, datos personales, ya que no permiten identificar a una persona física.

La retroalimentación humana podría incorporar observaciones asociadas a productores, especialistas o responsables de establecimientos. Si se registraran datos que permitan identificar a estas personas, su tratamiento deberá ajustarse a la Ley N° 25.326 de Protección de los Datos Personales y al Decreto Reglamentario N° 1558/2001. La información identificable se limitará a la necesaria para los objetivos de la investigación y se mantendrá con acceso restringido [1, 2].

La utilización de conjuntos de datos externos requerirá verificar su procedencia, licencia y condiciones de reutilización. El mismo criterio se aplicará a bibliotecas de software, modelos preentrenados y demás recursos empleados. Las versiones y condiciones de uso se documentarán para respetar la propiedad intelectual y permitir la reproducción del trabajo.

La trazabilidad comprenderá los conjuntos de datos, las operaciones de limpieza y transformación, las variables generadas, los datos sintéticos, las anomalías detectadas, las particiones experimentales y las versiones de los modelos. También incluirá los hiperparámetros, las métricas y los resultados de cada ejecución. Este registro permitirá reconstruir los experimentos y justificar las decisiones metodológicas sin ampliar el alcance funcional de la arquitectura.

12.2. Ética en el uso de inteligencia artificial

La arquitectura constituye un sistema de apoyo a la decisión. No sustituye el criterio agronómico ni adopta decisiones de riego de manera autónoma. Las alertas tempranas deberán ser interpretadas dentro de su contexto y estar sujetas a supervisión humana. Este criterio se sustenta en principios de transparencia, responsabilidad, robustez y gestión de riesgos aplicables al uso de inteligencia artificial [3, 4].

La representatividad de los datos constituye una limitación central. La escasez de registros, la variabilidad entre campañas, las diferencias entre cultivos y las condiciones particulares de cada establecimiento pueden afectar el desempeño del modelo predictivo. Por este motivo, los resultados no se generalizarán a escenarios que no se encuentren representados en la evaluación experimental.

La generación de datos sintéticos se utilizará para complementar conjuntos de entrenamiento limitados. Los registros generados permanecerán identificados y separados de las observaciones reales. Su incorporación no se considerará beneficiosa por definición. El aporte de este componente se determinará mediante la comparación de las configuraciones experimentales previstas.

La calidad de los datos influye directamente sobre las predicciones y las alertas. Los valores faltantes, los errores de sensores, las fallas de medición y los valores atípicos pueden introducir sesgos o degradar el desempeño. El componente de detección de anomalías permitirá identificar

estas situaciones. Las correcciones, imputaciones y exclusiones realizadas se conservarán como parte de la trazabilidad experimental.

La generación de alertas puede producir falsos positivos y falsos negativos. Los falsos positivos pueden promover verificaciones o intervenciones innecesarias. Los falsos negativos pueden impedir la detección oportuna de una condición de estrés hídrico. La evaluación considerará métricas acordes con ambos tipos de error y no se limitará a una medida global de desempeño.

La retroalimentación humana permitirá validar o corregir las alertas emitidas. Sin embargo, estas observaciones también pueden contener errores, diferencias de criterio o información incompleta. Antes de incorporarlas a la recalibración progresiva, se analizarán su consistencia, procedencia y contexto. Además, se conservará la relación entre cada observación y la versión del modelo sobre la que produjo efectos.

La transparencia metodológica se sostendrá mediante la documentación de los datos, las transformaciones, las variables, los algoritmos, los hiperparámetros y las métricas. También se explicitarán las limitaciones observadas y el dominio experimental de los resultados. Estos criterios permitirán interpretar el desempeño de la arquitectura y reconocer sus límites de generalización.

Finalmente, la evaluación de la arquitectura no se limitará al desempeño predictivo. También considerará la calidad de los datos, la trazabilidad experimental, la transparencia metodológica, la supervisión humana y las limitaciones de generalización de los resultados. De este modo, los criterios de gobernanza y ética acompañarán la investigación sin incorporar nuevos componentes ni modificar el alcance definido [3, 4, 5].

13. Gestión de riesgos

La gestión de riesgos tiene como propósito identificar, analizar y tratar aquellos eventos que podrían afectar el cumplimiento de los objetivos del proyecto, el desarrollo de la arquitectura de inteligencia artificial, la ejecución del plan experimental y la contrastación de la hipótesis de investigación.

Los riesgos identificados se relacionan principalmente con la disponibilidad y calidad de los datos, el desempeño de los modelos predictivos, la validación experimental y la planificación del proyecto. Su análisis permite definir acciones preventivas orientadas a reducir la probabilidad de ocurrencia y, cuando resulte posible, disminuir el impacto sobre el desarrollo del trabajo.

Para el análisis se adopta la metodología de número de prioridad de riesgo (*Risk Priority Number*, RPN), calculado como el producto entre la severidad (S) y la probabilidad de ocurrencia (O).

13.1. Identificación de los riesgos y estimación de sus consecuencias

Riesgo 1: disponibilidad insuficiente de *datasets* representativos

Existe la posibilidad de no disponer de conjuntos de datos suficientemente representativos para entrenar y evaluar adecuadamente la arquitectura propuesta.

Severidad (S): 9.

Justificación: la disponibilidad de datos constituye un elemento esencial para desarrollar y validar los modelos predictivos. Su ausencia comprometería directamente la contrastación de la hipótesis.

Probabilidad de ocurrencia (O): 5.

Justificación: existen *datasets* públicos disponibles, aunque no siempre presentan la cobertura, calidad o representatividad requerida para el problema específico.

Riesgo 2: baja calidad de los datos experimentales

Los conjuntos de datos pueden contener ruido, valores faltantes, inconsistencias o errores provenientes del proceso de adquisición.

Severidad (S): 8.

Justificación: una baja calidad de los datos puede afectar el entrenamiento de los modelos y disminuir la confiabilidad de las predicciones.

Probabilidad de ocurrencia (O): 6.

Justificación: la literatura reporta que este tipo de inconvenientes es frecuente en aplicaciones agrícolas basadas en sensores y datos abiertos.

Riesgo 3: la generación de datos sintéticos no produce mejoras significativas

Las técnicas de generación de datos sintéticos podrían no aportar mejoras medibles respecto del entrenamiento realizado únicamente con datos reales.

Severidad (S): 7.

Justificación: este componente forma parte de la hipótesis de investigación y constituye uno de los aspectos que se pretende evaluar experimentalmente.

Probabilidad de ocurrencia (O): 4.

Justificación: la evidencia publicada muestra resultados variables dependiendo del dominio y de la técnica utilizada.

Riesgo 4: el modelo predictivo no alcanza el desempeño esperado

Los algoritmos evaluados podrían no lograr niveles de desempeño suficientes para generar alertas tempranas confiables.

Severidad (S): 9.

Justificación: un bajo desempeño impediría demostrar el aporte de la arquitectura propuesta.

Probabilidad de ocurrencia (O): 5.

Justificación: el comportamiento de los modelos depende de la disponibilidad y calidad de los datos utilizados durante el entrenamiento.

Riesgo 5: elevada tasa de falsos positivos o falsos negativos

Las alertas generadas podrían presentar errores que disminuyan su utilidad como herramienta de apoyo para la toma de decisiones.

Severidad (S): 8.

Justificación: una tasa elevada de errores reduce la utilidad práctica de la arquitectura y afecta la evaluación experimental.

Probabilidad de ocurrencia (O): 5.

Justificación: este riesgo es habitual durante las primeras iteraciones de modelos predictivos.

Riesgo 6: dificultades para realizar la validación experimental

Podrían presentarse limitaciones para ejecutar completamente el protocolo experimental previsto o la prueba de concepto opcional.

Severidad (S): 7.

Justificación: la validación constituye una etapa fundamental para obtener evidencia que permita contrastar la hipótesis.

Probabilidad de ocurrencia (O): 4.

Justificación: la investigación contempla alternativas de validación mediante *datasets* públicos y simulaciones, lo que reduce parcialmente este riesgo.

Riesgo 7: retrasos en el cronograma del proyecto

La ejecución de actividades de investigación, experimentación o documentación podría requerir un esfuerzo superior al inicialmente estimado.

Severidad (S): 6.

Justificación: los retrasos podrían afectar las fechas previstas para la entrega del trabajo final.

Probabilidad de ocurrencia (O): 6.

Justificación: los proyectos de investigación suelen presentar incertidumbre asociada a la experimentación y al análisis de resultados.

Riesgo 8: disponibilidad limitada del director o de especialistas

La disponibilidad del director o de expertos de dominio podría verse reducida durante determinadas etapas del proyecto.

Severidad (S): 5.

Justificación: las revisiones metodológicas y técnicas constituyen un apoyo importante para el desarrollo del trabajo.

Probabilidad de ocurrencia (O): 4.

Justificación: las reuniones serán planificadas con anticipación y el proyecto contempla trabajo autónomo entre revisiones.

13.2. Tabla de gestión de riesgos

El número de prioridad de riesgo (RPN) se calcula mediante:

$$RPN = S \times O$$

Se adopta como criterio implementar acciones específicas de mitigación para aquellos riesgos cuyo valor inicial sea igual o superior a 30.

Cuadro 4. Matriz de gestión de riesgos

Riesgo	S	O	RPN	S*	O*	RPN*
R1	9	5	45	9	3	27
R2	8	6	48	8	3	24
R3	7	4	28	-	-	-
R4	9	5	45	8	3	24
R5	8	5	40	7	3	21
R6	7	4	28	-	-	-
R7	6	6	36	6	3	18
R8	5	4	20	-	-	-

13.3. Plan de mitigación

Riesgo 1: disponibilidad insuficiente de *datasets* representativos

Plan de mitigación:

Se ampliará la búsqueda de conjuntos de datos provenientes de repositorios científicos y plataformas de datos abiertos. Cuando resulte pertinente se evaluará la incorporación de técnicas de generación de datos sintéticos para complementar la información disponible, lo que mantendrá la diferenciación entre datos reales y sintéticos.

Severidad residual (S*): 9.

Probabilidad residual (O*): 3.

La probabilidad disminuye debido a la utilización de múltiples fuentes de información y a la estrategia prevista para complementar el conjunto experimental.

Riesgo 2: baja calidad de los datos experimentales

Plan de mitigación:

La arquitectura incorpora una etapa específica de preparación de datos que incluye limpieza, tratamiento de valores faltantes, normalización y detección de anomalías antes del entrenamiento de los modelos.

Severidad residual (S^*): 8.

Probabilidad residual (O^*): 3.

Riesgo 4: el modelo predictivo no alcanza el desempeño esperado

Plan de mitigación:

Se evaluarán distintas técnicas de aprendizaje automático, se realizará ajuste de hiperparámetros y se compararán múltiples configuraciones experimentales utilizando métricas objetivas de desempeño antes de seleccionar el modelo definitivo.

Severidad residual (S^*): 8.

Probabilidad residual (O^*): 3.

Riesgo 5: elevada tasa de falsos positivos o falsos negativos

Plan de mitigación:

La evaluación experimental contemplará múltiples métricas de desempeño, comparación de configuraciones, análisis de errores y retroalimentación humana para identificar oportunidades de mejora del modelo.

Severidad residual (S^*): 7.

Probabilidad residual (O^*): 3.

Riesgo 7: retrasos en el cronograma del proyecto

Plan de mitigación:

El seguimiento del avance se realizará mediante la planificación por sprints, reuniones periódicas con el director y actualización continua de la documentación técnica, lo que permitirá detectar desvíos de manera temprana.

Severidad residual (S^*): 6.

Probabilidad residual (O^*): 3.

14. Sprint Review

La revisión de sprint (*sprint review*) es una práctica fundamental en metodologías ágiles. Consiste en revisar y evaluar lo que se ha completado al finalizar un sprint. En esta instancia, se presentan los avances y se verifica si las funcionalidades cumplen con los criterios de aceptación establecidos. También se identifican entregables parciales y se consideran ajustes si es necesario.

Aunque el proyecto aún se encuentre en etapa de planificación, esta sección permite proyectar cómo se evaluarán las funcionalidades más importantes del backlog. Esta mirada anticipada favorece la planificación enfocada en valor y permite reflexionar sobre posibles obstáculos.

HU seleccionada	Tareas asociadas	Entregable esperado	¿Cómo sabrás que está cumplida?	Observaciones o riesgos
HU1	Elaborar la matriz comparativa de antecedentes. Identificar vacancias y criterios para el diseño de la arquitectura. Redactar el estado del arte y el marco conceptual.	Estado del arte y marco conceptual documentados.	Se identificaron y analizaron antecedentes relevantes, se documentaron las principales técnicas aplicables y se justificaron las decisiones metodológicas que orientan el diseño de la arquitectura.	La amplitud de la bibliografía puede dificultar la selección de antecedentes directamente relacionados con la hipótesis. Se deberá mantener el protocolo de búsqueda y los criterios de inclusión y exclusión definidos.
HU3	Implementar el método base de detección de anomalías. Implementar un prototipo de generación de datos sintéticos. Evaluar la similitud estadística y la utilidad predictiva de los datos sintéticos.	Componente de calidad y robustez de datos implementado e integrado.	El componente procesa los datos de entrada, ejecuta la detección de anomalías, integra la generación de datos sintéticos y produce información apta para el modelado predictivo.	La calidad insuficiente de los datos puede limitar la evaluación. Los datos sintéticos podrían no producir mejoras medibles y deberán mantenerse identificados y separados de los datos reales.

HU seleccionada	Tareas asociadas	Entregable esperado	¿Cómo sabrás que está cumplida?	Observaciones o riesgos
HU6	Integrar el componente de calidad con el componente predictivo. Integrar las alertas con el mecanismo de retroalimentación. Ejecutar pruebas funcionales de integración.	Arquitectura experimental integrada y operativa.	Los componentes intercambian información correctamente, el flujo completo se ejecuta sin errores, se generan alertas y la arquitectura queda preparada para la ejecución del plan experimental.	Pueden presentarse incompatibilidades entre estructuras de datos, contratos de integración o versiones de los componentes. Los ajustes deberán quedar registrados para conservar la trazabilidad.
HU8	Comparar el enfoque de referencia con la arquitectura propuesta, Analizar el aporte de los componentes incorporados. Contrastar los resultados con la hipótesis de investigación. Redactar los resultados, la discusión y las conclusiones.	Análisis de resultados, conclusiones y contrastación de la hipótesis.	Se compararon las configuraciones experimentales, se analizó el aporte de cada componente, se elaboraron conclusiones fundamentadas y se determinó el grado de respaldo obtenido para la hipótesis.	La evidencia puede resultar insuficiente o no mostrar mejoras significativas. Las conclusiones deberán respetar los resultados obtenidos y explicitar las limitaciones y amenazas a la validez.

15. Sprint Retrospective

La retrospectiva de sprint es una práctica orientada a la mejora continua. Al finalizar un sprint, se reflexionará sobre lo que funcionó bien, lo que puede mejorarse y qué acciones concretas pueden implementarse para trabajar mejor en el futuro.

Durante el desarrollo del proyecto se utilizará el método de la estrella de la retrospectiva, que organiza la reflexión en torno a cinco ejes:

- ¿Qué hacer más?
- ¿Qué hacer menos?
- ¿Qué mantener?
- ¿Qué empezar a hacer?
- ¿Qué dejar de hacer?

Aun en una etapa temprana, esta herramienta permite planificar la forma de trabajar, identificar anticipadamente posibles dificultades y diseñar estrategias de organización personal.

Durante toda la ejecución se reflexionará sobre las condiciones iniciales del proyecto, se identificarán fortalezas, posibles dificultades y estrategias de mejora, incluso antes del inicio del desarrollo.

Se completa la siguiente tabla en la que se toma como referencia los cinco ejes de la estrella de la retrospectiva (*starfish* o estrella de mar). Esta instancia ayudará a definir buenas prácticas desde el inicio y preparar para enfrentar el trabajo de forma organizada y flexible.

Sprint tipo y N°	¿Qué hacer más?	¿Qué hacer menos?	¿Qué mantener?	¿Qué empezar a hacer?	¿Qué dejar de hacer?
Sprint técnico 1	Profundizar el análisis de antecedentes científicos y técnicos directamente vinculados con la hipótesis	Ampliar las búsquedas sin aplicar los criterios de inclusión y exclusión definidos	El protocolo reproducible de búsqueda y el registro de las fuentes consultadas	Vincular cada antecedente relevante con una decisión metodológica o de arquitectura	Seleccionar técnicas por su popularidad sin considerar las características de los datos y del problema
Sprint técnico 3	Evaluar la calidad, procedencia y trazabilidad de los datos antes del entrenamiento	Aplicar transformaciones sin documentar su justificación, parámetros y efectos	La separación entre datos reales y sintéticos y la prevención de contaminación entre entrenamiento y evaluación	Registrar la procedencia, versión y transformaciones aplicadas a cada conjunto de datos	Utilizar conjuntos de datos cuya procedencia, licencia o calidad no puedan justificarse
Sprint técnico 7	Repetir los experimentos y ejecutar pruebas de ablación bajo los escenarios definidos	Obtener conclusiones a partir de una única ejecución o de una sola métrica	El registro de semillas, parámetros, versiones, configuraciones y resultados experimentales	Verificar la reproducibilidad de cada experimento antes de comparar configuraciones	Modificar parámetros experimentales sin registrar los cambios realizados
Sprint no técnico 0 (planificación)	Revisar la coherencia entre propósito, hipótesis, alcance, backlog, riesgos, cronograma y entregables	Acumular modificaciones sin actualizar la trazabilidad entre los capítulos	Las revisiones periódicas con el director y el control de versiones del documento	Mantener un registro de decisiones y del impacto de cada modificación propuesta	Modificar una sección sin verificar sus efectos sobre la hipótesis, el alcance, los riesgos, el cronograma y los entregables

Referencias

- [1] Congreso de la Nación Argentina. *Ley 25.326 de Protección de los Datos Personales*. 2000.
- [2] Poder Ejecutivo Nacional. *Decreto 1558/2001, reglamentación de la Ley 25.326*. 2001.
- [3] UNESCO. *Recommendation on the Ethics of Artificial Intelligence*. 2021.
- [4] Tabassi, E. *Artificial Intelligence Risk Management Framework (AI RMF 1.0)*. NIST AI 100-1, 2023.
- [5] Ragany, M., Wolfert, S. y Dara, R. *The governance of artificial intelligence in agriculture: A review and future research directions*. Outlook on Agriculture, 2026. DOI: 10.1177/00307270261450225.